

UNIVERSITA DEGLI STUDI DI MILANO-BICOCCA

Scuola di Economia e Statistica

Corso di laurea in

STATISTICA E GESTIONE DELLE INFORMAZIONI



**ANALISI MEDIANTE MODELLO MARKETING-MIX
APPLICATA AL SETTORE “SKINCARE”: UN CASO-STUDIO**

Public anonymized version

Tesi di Laurea di:

Lorenzo Gulizia

Anno Accademico 2023/2024

INDICE

INTRODUZIONE.....	1
1. INTRODUZIONE AI MARKETING MIX MODEL.....	3
1.1 CONTESTO DEL MARKETING MODERNO.....	3
1.2 MARKETING MIX MODEL	4
2. FONDAMENTI TEORICI	6
2.1 ACQUISIZIONE DEI DATI – VARIABILI DIPENDENTI E INDIPENDENTI.....	6
2.1.1 <i>Variabile Dipendente</i>	6
2.1.2 <i>Variabili Indipendenti</i>	6
2.1.3 <i>Granularità dei Dati</i>	11
2.1.4 <i>Effetti Halo e Cannibalization</i>	11
2.2 TRASFORMAZIONI DELLE VARIABILI MEDIA	12
2.2.1 <i>Trasformazione Adstock</i>	12
2.2.2 <i>Curve di Saturazione</i>	16
2.2.3 <i>Approcci Combinati</i>	18
2.3 APPROCCI DI MODELLIZZAZIONE.....	18
2.3.1 <i>Modelli di regressione lineare</i>	19
2.3.2 <i>Modelli di Regressione Non Lineare</i>	20
2.4 RISULTATI DEI MARKETING MIX MODEL.....	21
2.4.1 <i>Analisi dei Risultati</i>	22
2.5 LIMITAZIONI DEI MARKETING MIX MODEL	24
3. CASO STUDIO	26
3.1 CONTESTO DI ANALISI E DATASET	26
3.1.1 <i>Presentazione del dataset grezzo</i>	27
3.1.2 <i>Selezione delle Variabili</i>	29
3.1.3 <i>Analisi Esplorativa dei Dati</i>	31
3.2 APPLICAZIONE DELLA METODOLOGIA.....	45
3.2.1 <i>Scelta del modello e dell'algoritmo di stima</i>	46
3.3 MODELLIZZAZIONE DELLE VARIABILI MEDIATICHE	48
3.4 MODELLO FINALE E RISULTATI	59
3.5 RISULTATI DELL'ANALISI.....	71
CONCLUSIONI.....	78
BIBLIOGRAFIA	81
APPENDICE.....	83

Introduzione

Nel corso degli anni, la concezione del Marketing ha subito una notevole evoluzione. Edmund Jerome McCarthy nel 1960 propone la strategia basata sul Marketing Mix, un insieme di variabili che l'azienda può modulare per influenzare la domanda e la soddisfazione del suo mercato target. Nel contesto attuale, i professionisti del marketing devono adottare un approccio quantitativo alla comprensione dei loro mercati di riferimento. In particolare, è fondamentale per gli operatori di marketing quantificare l'efficacia del Marketing Mix attraverso analisi rigorose e basate su dati concreti. I Marketing Mix Model si sono affermati come uno degli strumenti di analisi più potenti per quantificare l'efficacia del marketing. Questo approccio analitico fornisce risposte statisticamente robuste a numerose questioni, tra cui: la valutazione del Ritorno sull'Investimento (ROI), l'analisi del contributo di ogni componente del Media Mix (con cui si intende il ricorso a diversi mezzi pubblicitari nell'ambito di una stessa strategia di comunicazione), l'ottimizzazione dell'allocazione dei budget e la previsione delle diverse campagne di Marketing e Media.

La presente tesi si propone di effettuare una disamina dei marketing mix model sul piano sia teorico sia applicativo, in quest'ultimo caso mediante l'analisi di un caso studio reale. In particolare, la sezione teorica mira ad esplorare i fondamenti metodologici dei Marketing Mix Models, partendo dalle variabili di interesse coinvolte nell'intero processo di analisi dell'efficacia del marketing aziendale, fino alla fase di modellizzazione, con la spiegazione delle diverse tecniche di trasformazione delle variabili Media, atte alla cattura dei diversi effetti pubblicitari, come il *carryover effect* e lo *shape effect*, che verranno successivamente esaminati. Questa sezione getterà le fondamenta teoriche per l'applicazione pratica successiva, che prevede l'analisi del marketing effettuato per un prodotto del settore *skincare* di una particolare azienda leader nel settore dei cosmetici, mediante Marketing Mix Model. Tale analisi verrà effettuata con il software R in ambiente RStudio mediante l'implementazione di un modello di regressione non lineare volto alla quantificazione delle leve di marketing, necessarie per ricavare informazioni sull'efficacia delle diverse strategie attuate dall'azienda.

L'elaborato si articola in tre capitoli principali:

1. il primo capitolo, "Introduzione ai Marketing Mix Model", è volto a fornire un'introduzione ai Marketing Mix Model con riferimento al marketing contemporaneo delineandone i principali obiettivi;
2. il secondo capitolo, "Fondamenti teorici", descrive la base teorica di questi modelli. Comprende una trattazione delle variabili raccolte non soltanto come input del modello, ma

anche come elementi per l'analisi dell'efficacia del marketing aziendale. Prosegue con una spiegazione delle diverse trasformazioni applicabili alle variabili di input del modello e con i possibili approcci di modellistica utilizzabili per la costruzione del Marketing Mix Model. Il capitolo descrive inoltre i risultati prodotti dalle analisi che misurano l'efficacia delle campagne di marketing ed infine vengono presentati i limiti di questi strumenti;

3. il terzo capitolo, "Caso Studio", presenta un caso studio concreto, nel quale si applica un Marketing Mix Model a un prodotto del settore skincare di un'azienda leader nel mercato dei cosmetici. Si descrivono le fasi di raccolta dati, la costruzione del modello, l'interpretazione dei risultati e delle informazioni ricavate, giustificando le scelte metodologiche effettuate.

1. Introduzione ai Marketing Mix Model

1.1 Contesto del marketing moderno

Il contesto del marketing moderno è caratterizzato da una crescente complessità e dalla necessità di adottare un approccio quantitativo per comprendere e influenzare in modo efficace i mercati in cui si opera. In questo scenario, il concetto di *marketing mix*, introdotto da Edmund Jerome McCarthy nel 1960, rimane un fondamento della strategia di marketing. Il marketing mix è definito come un insieme di azioni e soluzioni volte a soddisfare i bisogni dei consumatori e raggiungere gli obiettivi di marketing dell'azienda. Questo insieme di strumenti è tradizionalmente raggruppato in quattro categorie principali, note come le "4P" del marketing mix: Prodotto, Prezzo, Promozione e Posto (distribuzione)¹.

Il Prodotto si riferisce a qualsiasi bene o servizio che soddisfa una specifica esigenza del cliente. Il Prezzo è l'importo effettivo che ci si aspetta il cliente paghi per il prodotto, influenzando direttamente la percezione del valore e la decisione d'acquisto. La Promozione comprende tutte le strategie di comunicazione di marketing, come pubblicità, relazioni pubbliche e promozioni, volte a informare e persuadere i potenziali clienti. Infine, il Posto riguarda dove e come il prodotto viene venduto, includendo le decisioni sulla distribuzione e la logistica.

L'efficacia del marketing mix è cruciale per il successo o il fallimento di un prodotto o servizio nel mercato.

Nel contesto attuale, caratterizzato da una significativa evoluzione dell'ambiente di business, le aziende devono adattare le loro pratiche abituali, poiché i clienti stanno diventando più esigenti e le soluzioni di marketing tradizionali non sono più sufficienti. Le aziende devono espandere la gamma di servizi, soddisfare i bisogni degli acquirenti e ridurre i costi. È fondamentale allineare ed utilizzare efficacemente gli elementi del marketing mix e le loro azioni per raggiungere tale efficacia. Una gestione efficace del marketing mix consente ai marketer di creare una combinazione di elementi che permetta di gestire in modo ottimale il budget aziendale per raggiungere gli obiettivi desiderati. In questo contesto sono stati sviluppati strumenti analitici, come il Marketing Mix Model (MMM), utilizzati come strumento dalle aziende per stimare l'efficacia delle varie iniziative di marketing e aumentare il Ritorno sull'Investimento².

¹ Goi C. L. (2009). *A review of marketing mix: 4Ps or more*. International journal of marketing studies, 1(1).

² Dr. R. Jarrar, Mass Analytcs. *Your Comprehensive Marketing Mix Modeling Guide*.

1.2 Marketing Mix Model

Fornito il background di nascita dei Marketing Mix Model, è necessario introdurla per capire la loro struttura, lo sviluppo e come operano per il raggiungimento degli obiettivi cui sono preposti. I MMM sono difatti modelli econometrici che consentono di analizzare la relazione, lineare o meno, tra una variabile dipendente, solitamente espressa dai volumi di vendita o da altri indicatori di prestazione (*Key Performance Indicator*, KPI) rilevanti per l'azienda, e le iniziative di marketing³.

L'obiettivo primario di un Marketing Mix Model è misurare l'influenza delle diverse componenti del marketing mix sulle performance di vendite per un determinato prodotto. Questi modelli offrono la capacità di disaggregare il contributo di ciascuna leva di pianificazione commerciale, distinguendo tra due tipologie principali:

- il contributo di base: rappresenta le vendite del prodotto, indipendentemente dalle attività di marketing;
- il contributo incrementale: quantifica le variazioni nelle vendite attribuibili a specifici fattori come promozioni e attività media.

Le caratteristiche di tali strumenti permettono di fornire ai professionisti del marketing dettagli granulari sul contributo specifico di ogni singola variabile, consentendo loro di ottimizzare l'allocazione del budget e calcolare metriche rilevanti per l'azienda quali il ROI (Ritorno sull'Investimento).

Inoltre, uno degli obiettivi principali di un MMM è quantificare l'effetto delle campagne mediatiche pianificate. Durante la fase di modellizzazione, infatti, particolare attenzione viene posta alla cattura degli effetti pubblicitari, ciascuno dei quali richiede specifiche tecniche di trasformazione applicate alle variabili media, in modo da catturare quanti più possibili effetti che accadono nella realtà. Questi includono⁴:

- *effetto corrente*: la risposta immediata delle vendite a uno stimolo pubblicitario;
- *effetto carryover*: la persistenza, ovvero il ricordo, dell'impatto pubblicitario oltre il periodo di esposizione iniziale, catturato attraverso funzioni di Adstock (trattate nel capitolo 2);
- *effetto shape*: l'investimento pubblicitario è soggetto a rendimenti decrescenti una volta raggiunto il punto di saturazione di un determinato canale. Questo implica che,

³ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

⁴ S. Pandey, S. Gupta, S. Chhajer. (2021). *Marketing Mix Modeling (MMM) – Concepts and Model Interpretation*. INTERNATIONAL JOURNAL OF ENGINEERING RESEARCH & TECHNOLOGY (IJERT) Volume 10, Issue 06.

all'aumentare della spesa o dell'intensità della pubblicità su un canale specifico, il rendimento marginale tende a diminuire;

- *effetto di contenuto*: la variabilità nella risposta attribuibile a differenze nel contenuto creativo degli annunci, che viene definito “copy” e può comprendere anche un personaggio più o meno popolare coinvolto per la creazione di un contenuto pubblicitario;
- *effetto media*: l'eterogeneità nella risposta dettata dai diversi canali mediatici, sia tradizionali, quali la classica pubblicità televisiva, che digitali, vale a dire tutto ciò che concerne il social marketing;

Il processo di sviluppo di un Marketing Mix Model segue una struttura metodologica rigorosa, che comprende cinque fasi⁵:

1. definizione degli obiettivi di ricerca e dell'ambito di analisi, fase iniziale in cui è importante definire l'indirizzo dello studio e gli obiettivi che dovranno essere raggiunti;
2. acquisizione e preparazione dei dati, step fondamentale poiché i dati raccolti saranno funzionali alla costruzione del modello e al conseguimento di informazioni accurate. Questo evidenzia l'importanza di raccogliere dati puliti;
3. validazione e revisione critica dei dati raccolti, fase che implica un controllo di tutti gli insiemi di dati puliti e processati (difatti tale revisione potrebbe rivelare errori nei dati);
4. modellizzazione, fase nella quale si testano le variabili di input, si applicano le trasformazioni alle variabili media e si procede al *training* e alla validazione del modello;
5. risultati, ultima fase che consiste nell'interpretazione e nell'analisi dei risultati in modo da pervenire a nuove strategie di mercato oppure consolidare strategie già in essere.

In definitiva, questo approccio strutturato assicura che il modello sia basato su dati affidabili e che i risultati siano interpretati in modo accurato e contestualizzato.

In aggiunta, gli MMM si distinguono per la loro conformità alle normative sulla privacy, poiché utilizzano dati aggregati anziché informazioni a livello individuale, come i Cookie, che sono utilizzati, invece, nei modelli di attribuzione per identificare dove e quando un utente effettua una conversione, cioè una determinata azione, che può essere il semplice click al sito o l'acquisto di un determinato prodotto. Questa caratteristica dei Marketing Mix Model li rende adatti in un contesto di crescente attenzione alla protezione dei dati personali⁶.

⁵ Dr. R. Jarrar, Mass Analytics. *Your Comprehensive Marketing Mix Modeling Guide*.

⁶ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

2. Fondamenti teorici

Dopo aver discusso del contesto da cui nascono i Marketing Mix Model, averli definiti e colta la loro natura e scopi è necessario visualizzare più a fondo la struttura del modello.

In questo capitolo si discuterà delle variabili in input, distinguendo tra variabili dipendenti e indipendenti e differenziando queste ultime per categoria, e della granularità con cui i dati devono essere raccolti.

Verranno spiegate in modo dettagliato la trasformazione Adstock e le curve di saturazione applicabili alle variabili media, caratteristica peculiare dei MMM. Saranno elencati i principali possibili approcci alla modellistica, i risultati prodotti da uno studio mediante Marketing Mix Model ed infine le limitazioni di questi strumenti.

2.1 Acquisizione dei Dati – variabili dipendenti e indipendenti

2.1.1 Variabile Dipendente

La variabile dipendente in un Marketing Mix Model rappresenta il Key Performance Indicator (KPI) che si intende analizzare. La scelta di questa variabile è cruciale nel business e varia in base agli obiettivi specifici dell'analisi e al settore merceologico del cliente.

Come già affermato, solitamente, la variabile dipendente è rappresentata dal volume o valore delle vendite.

A seconda degli obiettivi del cliente e dell'analisi, la granularità della variabile dipendente può variare, permettendo di analizzare i dati a diversi livelli. Ad esempio, è possibile scegliere di impostare l'analisi per canale di vendita, dunque valutare il volume delle vendite provenienti dal solo e-commerce di un determinato prodotto o marchio. Altri livelli in cui è possibile analizzare i dati sono: per account, per regione, per categoria di prodotto e per singolo punto vendita. Dunque, la scelta del livello di granularità dipende dagli obiettivi specifici dell'analisi e dalla disponibilità dei dati⁷.

2.1.2 Variabili Indipendenti

Le variabili indipendenti in un MMM sono rappresentate da fattori specifici del contesto che sono idealmente divisi in tre categorie principali: 1) variabili di *baseline*, 2) variabili di media

⁷ Dr. R. Jarrar, Mass Analytics. *Your Comprehensive Marketing Mix Modeling Guide*.

e non-media marketing, che insieme rappresentano le variabili incrementali, infine le 3) variabili contestuali⁸.

1) VARIABILI DI BASELINE

Le variabili di baseline rappresentano gli elementi che interagiscono per determinare il volume di vendite di base, indipendentemente dalle attività di marketing.

Tra questi, si possono identificare le seguenti componenti principali⁹:

- *Prezzo*: il prezzo emerge come un fattore cruciale nella determinazione degli altri elementi della strategia di marketing mix, questo poiché, determina non solo il gruppo di consumatori target, ma anche le strategie di pubblicità, promozione e distribuzione;
- *Distribuzione*: un indicatore chiave in questo ambito è la Distribuzione Ponderata (WD - Weighted Distribution), che esprime la percentuale di negozi che hanno effettuato almeno una vendita del prodotto in questione, ponderata per il fatturato di ciascun negozio in relazione alla categoria di interesse. Questo indicatore fornisce una misura della presenza del prodotto nel mercato e della sua accessibilità ai consumatori;
- *Numero di referenze medio*: considerando tutti i tipi e i formati di un dato prodotto, rappresenta la media delle varianti di prodotto vendute in ogni negozio in una settimana;
- *Assortimento*: l'assortimento, calcolato come il prodotto tra il Numero di Referenze e la Distribuzione Ponderata, rappresenta la varietà e la disponibilità del prodotto sul mercato. Un assortimento ampio offre ai consumatori maggiori opzioni di scelta, influenzando positivamente le performance di vendita;
- *Stagionalità*: la stagionalità si riferisce alle variazioni periodiche nella domanda. Queste fluttuazioni possono manifestarsi come picchi di vendita durante specifiche stagioni o in corrispondenza di eventi ricorrenti come il Black Friday o le festività natalizie. In un Marketing Mix Model, la stagionalità è spesso modellizzata come una variabile settimanale (il cui valore medio è prossimo a 1) che esprime la stagionalità dell'intero mercato per un dato prodotto;
- *Variabili Macroeconomiche*: fattori come il Prodotto Interno Lordo (PIL), il tasso di disoccupazione e l'inflazione, pur non essendo direttamente controllabili dalle aziende, esercitano un'influenza rilevante sulle performance di mercato. L'inclusione di questi

⁸ LatentView (2019). A complete guide to Marketing Mix Modeling and use cases. URL <https://www.latentview.com/wp-content/uploads/2019/08/Marketing-Mix-Model.pdf>.

⁹ Acceleration, WPP Company. Manuale aziendale.

indicatori nei modelli MMM permette di contestualizzare le performance aziendali all'interno di un ampio scenario economico.

2) VARIABILI INCREMENTALI

Le variabili incrementali rappresentano essenzialmente le attività di marketing, che possono essere promozionali o di advertising e sono gli elementi controllabili del marketing mix che influenzano direttamente le performance di vendita. Nello specifico:

2a) Promozioni.

Le promozioni sono attività volte a stimolare le vendite, come sconti, offerte speciali o promozioni in-store. Per valutare l'impatto delle attività promozionali nei punti vendita, vengono utilizzate diverse metriche chiave¹⁰:

- *Intensità Promozionale*: una quantità calcolata come $\frac{VolumiPromo}{VolumiTotali}$ ed espressa in percentuale; è essenzialmente la percentuale di volumi che sono stati venduti sotto una determinata promozione;
- *Taglio Prezzo*: una quantità solitamente calcolata come $\frac{(PrezzoBase - PrezzoPromo)}{PrezzoBase}$;
- *WD Promo*: una quantità calcolata come la WD (Distribuzione Ponderata) ma considerando solo le vendite in promozione.

2b) Attività mediatiche.

Le variabili pubblicitarie, o variabili media, rappresentano uno degli elementi costitutivi più rilevanti dei Marketing Mix Model, dato che quantificano l'esposizione dei consumatori alle diverse attività di comunicazione marketing. Un piano media, solitamente, comprende sia campagne marketing offline che online, caratterizzate da differenti metriche e metodologie di misurazione¹¹.

Nel contesto della pubblicità offline, due attività emergono come predominanti: la televisione e la radio. La copertura raggiunta da un'attività pubblicitaria è espressa in termini di *Gross Rating Points* (GRP), che rappresentano una misura standardizzata all'esposizione pubblicitaria dei consumatori e sono calcolati secondo la seguente formula:

$$GRP = \frac{Impression}{Target Dimension} \cdot 100$$

¹⁰ Acceleration, WPP Company. Manuale aziendale.

¹¹ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

dove la quantità *Impression* al numeratore rappresenta il numero di contatti lordi raggiunti da una pubblicità, mentre al denominatore *Target Dimension* indica la numerosità della popolazione che rientra nel target di interesse¹².

Un modo alternativo di definire i GRP è:

$$GRP = Reach(\%) \cdot OTS \cdot 100$$

dove la quantità Reach può rappresentare il numero di contatti netti, se espressa in valore assoluto, o la percentuale della popolazione target potenzialmente esposta al messaggio pubblicitario. La quantità OTS (*Opportunity To See*) è l'unità di misura utilizzata per esprimere la frequenza media di una campagna pubblicitaria, ovvero il numero medio di volte in cui viene raggiunta ciascuna persona appartenente al target della campagna¹³. Inoltre, i GRP vengono calcolati per specifici segmenti demografici, in base alla popolazione target di interesse¹⁴.

Tra queste attività di pubblicità offline, la televisione riveste un ruolo di primaria importanza, poiché in questa attività si concentrano investimenti maggiori da parte degli operatori del marketing a causa dell'elevato costo di tale mezzo. Gli investimenti nella pubblicità televisiva sono variabili e portano, nei mesi, ad una eterogeneità delle campagne, che variano nel contenuto della pubblicità, dagli attori coinvolti, dal minutaggio degli spot fino alla dimensione vera e propria della campagna, che porterà a una maggiore o minore copertura mediatica. È per questo motivo che una delle strategie più utilizzate nei Marketing Mix Model per modellizzare queste variabili è la suddivisione della comunicazione televisiva in *flight*, in ognuno dei quali viene racchiusa una specifica campagna o più campagne a seconda delle strategie di clustering.

Per quanto riguarda l'*online advertising*, i principali canali digitali includono il Display advertising, il Search marketing, i Social media, il Video advertising (come YouTube) e la Connected TV (CTV). Ciascuno di questi canali può essere ulteriormente suddiviso in sottocategorie, ad esempio è possibile una sottodivisione dei social media, facendo distinzione tra Tik Tok, Meta e altri social.

Prima di delineare le metriche che misurano l'impatto e l'intensità dei mezzi pubblicitari digitali è necessario definirli più chiaramente:

- il Display Advertising è una forma di pubblicità digitale che utilizza banner, immagini, video o animazioni per promuovere prodotti o servizi su siti web;

¹² Auditel. *Glossario*. URL <https://www.auditel.it/glossario/>.

¹³ Auditel. *Glossario*. URL <https://www.auditel.it/glossario/>.

¹⁴ Acceleration, WPP Company. Manuale aziendale.

- il Search Marketing è un'attività di web marketing volta a migliorare la visibilità di un sito web sui motori di ricerca;
- la Connected TV (CTV) si riferisce generalmente a una smart TV.

Per questi canali, le metriche principali di valutazione dell'impatto mediatico sono le Impression per Display Advertising, i Social media, i Video advertising e le Connected TV. Per il Search Marketing, invece, la metrica di valutazione sono i click, che misurano le interazioni dirette degli utenti con gli annunci.

È importante notare che tra le attività mediatiche, sono considerate, come variabili, solo le distribuzioni dei contatti raggiunti dalle pubblicità, ovvero GRP e le Impressions. Inoltre, anche se non utilizzati come dati di input nel modello, sono rilevanti gli investimenti relativi a tali campagne pubblicitarie. Queste variabili sono usate nel calcolo di KPI come il ROI, una volta estratti gli output del modello e ottenuti i contributi incrementali delle variabili mediatiche¹⁵.

3) VARIABILI CONTESTUALI

Le variabili contestuali nei Marketing Mix Model rappresentano fattori esterni che possono avere un impatto sulle performance di vendita¹⁶.

Tra le variabili contestuali sono presenti le festività e gli eventi speciali. Questi eventi possono essere inseriti nel modello attraverso l'uso di variabili dummy che assumono il valore 1 durante il periodo dell'evento e 0 altrimenti, permettendo di quantificare l'impatto di questi eventi sulle vendite. Esempi di tali eventi includono festività come Natale, Pasqua, o eventi commerciali come il Black Friday. L'inclusione di queste variabili nei modelli permette di catturare l'effetto di picchi di vendita stagionali o legati a particolari occasioni.

Un'altra categoria di variabili contestuali sono le attività dei *competitor*. Queste variabili possono comprendere la dimensione della copertura mediatica di campagne marketing lanciate dai competitor e le loro attività promozionali. L'inclusione di queste variabili permette di valutare come le azioni dei concorrenti di mercato influenzino le performance dell'azienda. Ad esempio, una campagna pubblicitaria aggressiva da parte di un competitor di una determinata azienda potrebbe influenzare negativamente le vendite.

Inoltre, in relazione alla tipologia di concorrenza, è possibile distinguere tra concorrenza diretta e indiretta. I concorrenti diretti offrono prodotti o servizi simili, mentre quelli indiretti soddisfano lo stesso bisogno del consumatore in modo alternativo. Un esempio è il confronto

¹⁵ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

¹⁶ LatentView (2019). A complete guide to Marketing Mix Modeling and use cases. URL <https://www.latentview.com/wp-content/uploads/2019/08/Marketing-Mix-Model.pdf>.

tra smartphone di marche diverse (concorrenza diretta) e tra dispositivi di lettura elettronica e libri tradizionali (concorrenza indiretta).

2.1.3 Granularità dei Dati

Nella fase di raccolta dati è importante considerare sia l'orizzonte temporale della serie storica che la granularità dei dati, per ottenere risultati esaustivi e robusti.

Per quanto concerne l'orizzonte temporale, si raccomanda l'utilizzo di un minimo di due anni di dati storici settimanali, con una scelta ottimale, se possibile, di tre anni. Qualora fossero disponibili esclusivamente dati mensili, è consigliabile estendere il periodo di osservazione a 4-5 anni¹⁷.

Vi sono diversi vantaggi rilevanti nel raccogliere dati più granulari. In aggiunta a modelli più accurati, l'utilizzo di dati più granulari produrrà a sua volta risultati più granulari, in modo da distinguere con maggior precisione l'impatto delle diverse strategie di marketing sul volume delle vendite.

Nonostante gli indubbi vantaggi, ottenere e utilizzare nell'analisi dati più granulari non sempre risulta una possibilità accessibile poiché non sempre si hanno disponibili dati granulari a seconda della fonte dati.

Per tal motivo la scelta del livello di granularità deve essere giustificata dagli obiettivi specifici dell'analisi e dal tipo di informazioni che si vuole generare¹⁸.

2.1.4 Effetti Halo e Cannibalization

L'effetto alone (*halo effect*) è un concetto che descrive la preferenza di un consumatore verso un prodotto di una marca dovuta alle esperienze positive che ha avuto con altri prodotti della stessa marca. L'effetto alone può essere visto come una misura della forza del marchio e della fedeltà alla marca¹⁹.

Per esempio, i consumatori preferiscono i tablet di un determinato marchio basandosi sull'esperienza positiva che hanno avuto con gli smartphone di quel marchio. Questo implica che, la comunicazione di un certo prodotto del marchio può avere un impatto positivo sulle vendite di un altro prodotto dello stesso brand.

¹⁷ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

¹⁸ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

¹⁹ LatentView (2019). A complete guide to Marketing Mix Modeling and use cases. URL

L'effetto di cannibalizzazione si riferisce invece all'impatto negativo su un prodotto di una marca a causa delle prestazioni di altri prodotti della stessa marca. Questo si verifica principalmente nei casi in cui i marchi hanno più prodotti in categorie simili²⁰.

Quindi, nei Marketing Mix Model, le variabili baseline o incremental, come la comunicazione, di altri prodotti dello stesso marchio vengono testate per evidenziare la presenza dell'effetto alone o di cannibalizzazione sulle performance di vendita del prodotto in esame.

2.2 Trasformazioni delle Variabili Media

Dopo aver introdotto le variabili di input nei Marketing Mix Model ed effettuata una disamina delle variabili delle attività mediatiche, è necessario affrontare le possibili tecniche di trasformazione di queste variabili.

Uno dei principali obiettivi dei MMM è cogliere gli effetti della pubblicità illustrati in precedenza, tra cui l'effetto *carryover* e l'effetto *shape*. Difatti i Marketing Mix Model si basano su due principali ipotesi:

- l'investimento pubblicitario ha un effetto ritardato e persistente nel tempo, definito *carryover* o *lagged effect*. Questo concetto implica che l'impatto della pubblicità non si esaurisce immediatamente, ma continua a influenzare il modo in cui i consumatori pensano, sentono e agiscono in relazione a un prodotto o un marchio, anche dopo che la campagna pubblicitaria è terminata;
- la relazione non lineare tra aumento degli investimenti pubblicitari o intensità della pubblicità e risposta delle vendite viene definito *shape effect*. Tale effetto è rappresentato da curve di saturazione, i cui approcci comuni sono l'utilizzo di funzioni a forma sigmoidea o logaritmiche, che esprimono quanto l'investimento è proficuo e quanto è ancora possibile investire, fino al raggiungimento del punto di saturazione.

2.2.1 Trasformazione Adstock

L'effetto di decadimento può essere modellizzato matematicamente mediante una trasformazione così detta Adstock²¹. Questa trasformazione permette di rappresentare analiticamente l'effetto carryover di una data una serie storica di N dati pubblicitari $x_1, x_2, \dots$,

²⁰ LatentView (2019). A complete guide to Marketing Mix Modeling and use cases. URL

²¹ Joseph J. V. (2006). *Understanding advertising Adstock transformations*.

x_N , di un mezzo m al variare del tempo t , con $t = 0, 1, \dots, T$, mediante la seguente formulazione generale della funzione Adstock:

$$adstock(x_{m,t}|w_m, L) = \sum_{l=0}^L w_m(l) x_{m,t-l}$$

dove L rappresenta la durata massima del “ricordo” della pubblicità, di un determinato mezzo, generalmente espresso in settimane. Questo parametro viene assunto come più duraturo per mezzi televisivi e più breve per mezzi digitali. L’indice l denota il termine di ritardo, ovvero indica la posizione corrente del ritardo sulla durata massima dell’effetto L , e assume valori $l = 0, \dots, L - 1$. Nell’applicazione tecnica l’indice l è definito come “Shift”, o più semplicemente, “Passi” della variabile media x_m dal tempo $t = 0$. Infine, w_m è una funzione peso che determina come l’effetto pubblicitario si distribuisce nel tempo.

La forma funzionale di w_m varia a seconda della scelta dell’AdStock con cui viene modellizzato l’effetto carryover; quella più comune è il *geometric decay*, una funzione di decadimento esponenziale a un parametro ed espressa dalla seguente formulazione:

$$w_m(l; \alpha_m) = \alpha_m^l \text{ con } 0 < \alpha_m < 1;$$

dove α_m è il parametro di decadimento fisso ed esprime l’effetto pubblicitario mantenuto all’ l -esimo ritardo dal tempo $t = 0$. Se $l = 0$ allora $\alpha_m = 1$, dunque all’aumentare di l , α_m tenderà a 0, esprimendo matematicamente il decadimento dell’effetto pubblicitario sino a quando non smetterà di avere influenza sui consumatori. La situazione in cui $l = 0$ e dunque $\alpha_m = 1$ viene definito “peak effect”, o effetto di picco, ovvero quando l’effetto pubblicitario raggiunge la sua massima intensità. Si evince che, secondo l’AdStock geometrico l’impatto massimo della comunicazione si otterrà all’inizio delle attività mediatiche²².

Esistono diversi approcci alla trasformazione Adstock, la cui formulazione generica rimane invariata e ciò che cambia nei vari modelli è la funzione peso w_m . Sebbene il decadimento geometrico sia il più comune e ampiamente implementato nella funzione Adstock, altre soluzioni consentono di modellizzare l’effetto pubblicitario in modo più flessibile. Ad esempio, alcune attività mediatiche potrebbero presentare un pattern più complesso, e l’impatto massimo dell’effetto, noto come peak effect, potrebbe non verificarsi immediatamente. Queste soluzioni alternative sono rappresentate dal *delayed Adstock* e dal *Weibull Adstock*.

²² Y. Jin, Y. Wang, Y. Sun, D. Chan, J. Koehler. (2017). *Bayesian methods for media mix modeling with carryover and shape effects*. Google Inc.

Il *delayed Adstock* assume un ritardo nell'effetto di picco introducendo il parametro θ_m , come affermato precedentemente, ciò che varia nella formulazione di questo approccio è la funzione peso w_m , espressa come:

$$w_m(l; \alpha_m^l, \theta_m) = \alpha_m^{(l-\theta_m)^2} \text{ con: } l = 0, \dots, L-1, 0 < \alpha_m < 1, 0 \leq \theta_m \leq L-1$$

dove θ_m è il parametro che rappresenta il ritardo nell'effetto di picco. Questa funzione peso w_m , con la sua forma a campana permette di catturare in modo efficace tale ritardo.²³

La Figura 1 espone il confronto tra la funzione di Adstock geometrico, indicata in nero, e quella di Adstock ritardato, indicato in rosso, al fine di rappresentare in modo più evidente i concetti discussi.




Figura 1- Delayed Adstock e Geometric Adstock ²⁴

La seconda soluzione precedentemente introdotta è l'Adstock Weibull, che offre una maggiore flessibilità nella modellizzazione dell'effetto pubblicitario. L'Adstock Weibull si basa sulla distribuzione di Weibull e può essere espresso in due forme principali: la Cumulative Distribution Function (CDF) e la Probability Density Function (PDF).

La CDF dell'Adstock Weibull a due parametri dipende dal parametro di scala η e dal parametro di forma β , ed è espressa come segue:

²³ Y. Jin, Y. Wang, Y. Sun, D. Chan, J. Koehler. (2017). *Bayesian methods for media mix modeling with carryover and shape effects*. Google Inc.

²⁴ Y. Jin, Y. Wang, Y. Sun, D. Chan, J. Koehler. (2017). *Bayesian methods for media mix modeling with carryover and shape effects*. Google Inc.

$$F(x) = 1 - \exp \left[- \left(\frac{x}{\eta} \right)^\beta \right]; x > 0 \text{ }^{25}.$$

La funzione peso w_m per la CDF dell'Adstock Weibull è espressa in termini di questi parametri, dove β (forma) controlla la curvatura della curva di decadimento e η (scala) determina il punto di flesso, influenzando la velocità del decadimento. Per esempio, un valore di shape pari a 1 produrrà una curva simile all' Adstock geometrico, mentre valori superiori a 1 generano curve a S più pronunciate²⁶.

La PDF dell'Adstock Weibull, d'altra parte, offre un effetto ritardato più evidente ed è espressa come segue:

$$f(x; \eta, \beta) = \frac{dF(x)}{dx} = \frac{\beta}{\eta} \left[\frac{x}{\eta} \right]^{\beta-1} \cdot \exp \left[- \left(\frac{x}{\eta} \right)^\beta \right] \text{ }^{27}.$$

La sua funzione peso w_m è definita in modo simile, ma il suo comportamento varia significativamente in base al valore del parametro shape. Ad esempio, con $\beta > 2$ si otterrà un effetto ritardato con un picco dopo l'esposizione iniziale, mentre con $0 < \beta < 1$, l'effetto di picco è immediato, con un rapido decadimento²⁸.

La principale differenza tra CDF e PDF risiede nella loro capacità di rappresentare l'effetto ritardato della pubblicità. Mentre la CDF è più adatta a modellizzare il decadimento cumulativo dell'effetto pubblicitario, la PDF eccelle nel catturare effetti ritardati e picchi non immediati. Questa flessibilità rende l'Adstock Weibull particolarmente utile per prodotti o servizi con cicli di conversione più lunghi o complessi, come il settore automobilistico.

Dalla Figura 2 è possibile visualizzare più chiaramente le differenze tra Adstock CDF e PDF al variare dei parametri di forma e scala.

²⁵ McCool J. I. (2012). *Using the Weibull distribution: reliability, modeling, and inference* (Vol. 950). John Wiley & Sons.

²⁶ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

²⁷ McCool J. I. (2012). *Using the Weibull distribution: reliability, modeling, and inference* (Vol. 950). John Wiley & Sons.

²⁸ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

Weibull Adstock CDF vs PDF (Flexible decay rate)

Half-life = time until effect reduces to 50%




Figura 2- Weibull Adstock²⁹

2.2.2 Curve di Saturazione

Il secondo effetto fondamentale nei Marketing Mix Model che è necessario modellizzare matematicamente è lo *shape effect*. Questo effetto riflette la relazione non lineare tra l'aumento degli investimenti pubblicitari, o l'intensità della pubblicità, e la risposta delle vendite ed è rappresentato da curve di saturazione. Più precisamente si tratta della teoria dei rendimenti decrescenti, nota anche come saturazione, un principio fondamentale in economia e marketing che descrive come l'efficacia di un investimento diminuisce all'aumentare di esso. Nel contesto della pubblicità, questa teoria afferma che ogni unità aggiuntiva di investimento pubblicitario continua a generare una risposta positiva in termini di risultati, ma l'incremento di tale risposta diventa progressivamente più piccolo³⁰.

Per modellizzare l'effetto *shape* della pubblicità, è necessario applicare una trasformazione non lineare alle variabili media. A tal scopo si utilizza comunemente la funzione Hill che ha le sue origini in farmacologia e fornisce una funzione flessibile per la trasformazione

²⁹ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

³⁰ Brue S. L. (1993). *Retrospectives: The law of diminishing returns*. Journal of Economic Perspectives, 7(3), 185-192.

delle variabili media, in grado di produrre curve di saturazione a S o a C. La funzione Hill è definita come segue:

$$Hill(x_{t,m}, k_m, s_m) = \frac{1}{1 + (x_{t,m}/k_m)^{-s_m}}$$

dove $x_{t,m}$ è la variabile media al tempo t di un mezzo m . Il parametro k_m è il punto di mezza saturazione; rappresenta il punto di flesso della curva, dove l'effetto dell'investimento è al 50% del suo massimo potenziale e dove la curva cambia di segno, segnalando una rapida accelerazione verso la saturazione completa. Il parametro s_m , invece, è il parametro di forma che determina la pendenza della curva³¹.

Vi sono altre trasformazioni applicabili per catturare l'effetto *shape*, come quella logaritmica ed esponenziale, che seppur generano una forma diversa di curva, l'interpretazione rimane la medesima.

La Figura 3 mostra la curva al variare dei parametri di mezza saturazione, indicato con *gamma*, e di forma, indicato con *alpha*.




Figura 3 -Hill Function³²

³¹ Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

³² Meta. Robyn. URL <https://facebookexperimental.github.io/Robyn/>

2.2.3 Approcci Combinati

La combinazione dell'Adstock e delle curve di saturazione compongono la trasformazione completa da applicare alle variabili media. Questa integrazione permette di modellizzare sia l'effetto carryover che l'effetto shape in un'unica struttura. Ci sono due possibili approcci per combinare questi effetti:

- applicare prima la trasformazione Adstock e poi la curva di saturazione.
- applicare prima la curva di saturazione e poi la trasformazione Adstock.

La scelta di un approccio o dell'altro non genera particolari differenze sul piano pratico dato che entrambi riescono a catturare sia l'effetto di saturazione che quello carryover; tuttavia, vi sono preferenze a seconda della natura dell'investimento pubblicitario.

Se la spesa in ogni periodo è relativamente piccola rispetto alla spesa cumulativa su più periodi, è preferibile applicare la trasformazione shape dopo l'Adstock. Questo perché l'effetto di saturazione su piccole spese individuali potrebbe essere trascurabile, per questo motivo introdurre prima l'effetto di ritardo dell'Adstock potrebbe contribuire a cogliere in modo più evidente la saturazione dell'investimento, andando a considerare non solo la spesa cumulativa, ma anche quantità di spesa maggiori dovute all'Adstock. Contrariamente, se la spesa media è molto intensa in alcuni periodi singoli, con campagne che si “accendono” e “spengono”, potrebbe essere preferibile prima catturare l'effetto di saturazione del grande investimento, e successivamente cogliere la distribuzione del ricordo pubblicitario nel tempo³³.

2.3 Approcci di Modellizzazione

I Marketing Mix Model possono essere costruiti in molti modi, esistono infatti diversi approcci per modellizzare le relazioni tra le variabili di marketing e le vendite relative a un prodotto. La scelta del modello più appropriato dipende da vari fattori, tra cui la complessità delle relazioni da catturare e gli obiettivi specifici dell'analisi. È bene utilizzare il modello che fornisce il trade-off più efficace tra cattura delle relazioni tra variabili, molto spesso non lineari e non linearizzabili, e interpretabilità dei risultati. Tuttavia, la scelta del modello dipende anche dalla necessità, dovuta dagli obiettivi dello studio, di cogliere determinati effetti pubblicitari rilevanti per l'analisi. Ad esempio, qualora fosse necessario cogliere l'effetto di saturazione di un

³³ Y. Jin, Y. Wang, Y. Sun, D. Chan, J. Koehler. (2017). *Bayesian methods for media mix modeling with carryover and shape effects*. Google Inc.

particolare mezzo pubblicitario, un modello di regressione lineare non sarebbe sufficiente, così che la scelta dovrebbe propendere a favore dell'utilizzo di un modello differente.

In questa sezione, verranno presentati i più comuni approcci di modellizzazione utilizzati nel Marketing Mix Modeling, evidenziandone i vantaggi e le limitazioni. Tra i modelli più popolari sono presenti i modelli di regressione lineare e non lineare, precedentemente citati. Oltre a questi vi sono modelli più complessi, una categoria che comprende approcci più sofisticati come i modelli gerarchici, bayesiani e marketing mix model basati su IA (ad esempio, il pacchetto *Robyn* sviluppato da Meta Marketing Science). Questi modelli, sebbene più complessi, permettono di catturare strutture di dati più articolate e in modo più efficiente.

2.3.1 Modelli di regressione lineare

I modelli di regressione lineare rappresentano l'approccio più semplice nel Marketing Mix Modeling, poiché assumono una relazione lineare tra le leve di marketing e i volumi delle vendite del prodotto o servizio in esame.

Un Marketing Mix Model basato sulla regressione lineare può avere la seguente struttura:

$$vol. vendite = \beta_0 + \beta_1 stagionalità + \beta_2 promo + \beta_3 prezzo base + \beta_4 TV + \beta_5 Meta + \varepsilon,$$

dove *vol. vendite* è la variabile dipendente e *stagionalità, promo, prezzo base, TV e Meta (Facebook)* sono le possibili variabili indipendenti di un MMM, le variabili in gioco in un Marketing Mix Model illustrate nella sezione 2.1. β_0 è l'intercetta $\beta_j, j = 1, \dots, 5$ sono i coefficienti di regressione stimati tipicamente mediante il metodo dei minimi quadrati ordinari (*Ordinary Least Squares* – OLS). Infine, ε denota il termine di errore casuale.

La regressione lineare è un approccio vantaggioso soprattutto dal punto di vista dell'interpretabilità dei risultati, in quanto molto semplice. Questo è derivato dal fatto che i coefficienti β rappresentano direttamente l'effetto di ciascuna variabile di marketing sulle vendite al netto delle altre variabili inserite nel modello, rendendo immediato il calcolo dei contributi delle varie leve. Inoltre, la facilità di implementazione e la rapidità computazionale rendono questi modelli molto popolari.

Tuttavia, questo approccio non è esente da criticità, anzi, le sue limitazioni risultano rilevanti nel contesto del Marketing Mix Modeling. La principale è l'assunzione di linearità, che spesso non riflette la realtà delle dinamiche di mercato; ad esempio, non è lineare la relazione tra aumento degli investimenti e risposta delle vendite, secondo la teoria dei rendimenti decrescenti, e le relazioni tra le variabili. Difatti l'unico effetto pubblicitario che questo tipo di modello

riesce a catturare è l'effetto corrente, presentato nella sezione 1.2, ossia la risposta immediata delle vendite a uno stimolo pubblicitario³⁴.

Inoltre, questi modelli non sono in grado di cogliere interazioni complesse tra le diverse variabili di marketing, ad esempio come la stagionalità o il prezzo del prodotto influiscano a loro volta sulle strategie di marketing.

Si evince che, per effettuare un'analisi più precisa e catturare la complessità delle dinamiche di mercato moderne, è spesso necessario ricorrere ad approcci più sofisticati e flessibili, come i modelli di regressione non lineare o tecniche più avanzate.

2.3.2 Modelli di Regressione Non Lineare

Per superare le limitazioni dei modelli di regressione lineare, un approccio utilizzato per i Marketing Mix Model è la regressione non lineare. In particolare, tra i modelli non lineari, quelli moltiplicativi risultano significativamente efficaci nel catturare le relazioni tipiche delle dinamiche di mercato, cosa che la prima tipologia di modelli non era in grado di effettuare appieno.

La forma generale di un modello moltiplicativo può essere espressa come:

$$Y = e^{\beta_0} \cdot \beta_1 x_1 \cdot \beta_2 x_2 \cdots \beta_n x_n \cdot \varepsilon .^{35}$$

Questi modelli non solo catturano gli effetti moltiplicativi tra le variabili di marketing, ma consentono anche di interpretare i coefficienti come elasticità dopo una trasformazione logaritmica. Questa trasformazione permette di misurare la variazione percentuale della variabile dipendente in risposta a una variazione percentuale dell'1% della variabile indipendente.

Tuttavia, un modello di questo tipo risulta ancora poco produttivo, in quanto assume che tutte le variabili interagiscano in modo moltiplicativo, il che potrebbe non riflettere accuratamente tutte le relazioni di mercato. Infatti, alcune variabili potrebbero non avere necessariamente effetti moltiplicativi. Inoltre, riesce a catturare solo l'effetto corrente e l'effetto shape, con la limitazione che per quest'ultimo effetto non è possibile ottenere curve di saturazione ad S ricavate mediante funzione Hill.

³⁴ S. Pandey, S. Gupta, S. Chhajed. (2021). *Marketing Mix Modeling (MMM) – Concepts and Model Interpretation*. INTERNATIONAL JOURNAL OF ENGINEERING RESEARCH & TECHNOLOGY (IJERT) Volume 10, Issue 06.

³⁵ . Pandey, S. Gupta, S. Chhajed. (2021). *Marketing Mix Modeling (MMM) – Concepts and Model Interpretation*. INTERNATIONAL JOURNAL OF ENGINEERING RESEARCH & TECHNOLOGY (IJERT) Volume 10, Issue 06.

Oltre ai modelli moltiplicativi semplici, esistono modelli non lineari più complessi che combinano componenti moltiplicative ed additive, andando ancora una volta a rimediare alle limitazioni degli approcci precedenti. Questi modelli possono includere trasformazioni Adstock e curve di saturazione per catturare gli effetti di carryover e i rendimenti decrescenti della pubblicità. Un esempio di tale equazione potrebbe assumere la forma:

$$Y = (X_1^{\beta_1} \cdot X_2^{\beta_2}) \cdot (\beta_0 + \beta_3 x_3 + \beta_4 x_4 + f(TV_{Adstock}) + f(Digital_{Adstock})),$$

dove $f(x_m)$ rappresenta una funzione non lineare che incorpora effetti Adstock e di saturazione di ciascun mezzo m ³⁶.

Questi modelli non lineari più complessi offrono una maggiore flessibilità nella modellizzazione delle dinamiche di marketing, permettendo di catturare effetti moltiplicativi, additivi e non lineari, tra cui il *carryover effect* e *shape effect*, che, contrariamente all'approccio precedente, sarà possibile catturare anche con curve di risposta ad S, utilizzando la funzione Hill. Tuttavia, tali modelli, date le relazioni fortemente non lineari, non possono essere linearizzati e aumentano la complessità nella stima dei parametri, generando possibili problemi di convergenza dell'algoritmo.

Ciò nonostante, anche questi modelli presentano delle sfide, anche se non più interessate alla capacità di catturare gli effetti pubblicitari e relazioni delle variabili rilevanti in un contesto di marketing, dato che questi modelli di regressione non lineare si presentano come strumenti potenti e flessibili. Tali sfide, invece, sono rivolte alla sfera pratica, in quanto la stima dei parametri di questi modelli può richiedere uno sforzo computazionale non indifferente ed è molto sensibile alla scelta dei valori iniziali. In aggiunta sono modelli soggetti a *overfitting* data la loro flessibilità e, a causa delle relazioni non lineari tra le variabili, potrebbero causare problemi nell'interpretazione dei risultati³⁷.

2.4 Risultati dei Marketing Mix Model

Una volta scelto l'approccio migliore con cui affrontare la fase di modellizzazione e terminata quest'ultima, si giunge all'interpretazione dei risultati e all'estrazione di informazioni utili allo

³⁶ Acceleration, WPP Company. Manuale aziendale.

³⁷ Pandey, S. Gupta, S. Chhajed. (2021). *Marketing Mix Modeling (MMM) – Concepts and Model Interpretation*. INTERNATIONAL JOURNAL OF ENGINEERING RESEARCH & TECHNOLOGY (IJERT) Volume 10, Issue 06.

sviluppo di strategie di mercato. Oltre a produrre risultati statisticamente robusti è importante che essi siano plausibili dal punto di vista del business.

I risultati derivanti da un MMM sono molteplici e possono fornire una comprensione approfondita dell'efficacia delle attività di marketing, in modo da guidare attività e strategie aziendali future.

L'analisi dei risultati per i canali di investimento può essere granulare. Infatti, le informazioni sono fornite non solo a totale per ogni mezzo di comunicazione, ma anche per ogni flight di quel determinato mezzo, ovvero una suddivisione della campagna marketing secondo diversi criteri come il periodo temporale in cui una campagna è stata lanciata. Da tale flessibilità si deduce la significativa importanza per l'azienda dei risultati forniti da uno studio mediante Marketing Mix Model.

2.4.1 Analisi dei Risultati

L'analisi dei contributi è il primo risultato che si procede ad analizzare, si tratta di scomporre le vendite totali per ogni variabile indipendente, distinguendo per vendite di base e vendite incremental. Concetto enunciato nella sezione 1.2 che divide le vendite generate indipendentemente dalle attività di marketing, da quelle ottenute dalle strategie mediatiche e promozionali. Come si osserverà nella sezione relativa al caso studio e da quanto affermato nella sezione 2.3.2, tale divisione non sempre è immediata, dato che nei modelli moltiplicativi, capaci di cogliere le relazioni delle dinamiche di mercato tra le variabili, le componenti di base modulano quelle incremental.

Per ottenere questa scomposizione, i coefficienti stimati per ciascuna variabile indipendente vengono moltiplicati per i rispettivi valori delle variabili. Il risultato di questa analisi permette agli operatori di marketing di cogliere in maniera immediata i fattori che determinano le migliori performance di vendita. Da questo output è facilmente osservabile anche l'impatto che i *competitor* di un prodotto o servizio hanno avuto sulle performance aziendali, dunque l'erosione di vendita generata. Da questa prima analisi si evidenzia se i risultati ottenuti sono plausibili dal punto di vista del business e in linea con i benchmark del settore³⁸.

Un secondo risultato valutabile è il Ritorno sull'Investimento, o ROI, che mostra, per ogni canale di investimento, il rendimento e l'efficienza delle attività di comunicazione e di marketing. Tale indicatore è espresso come:

³⁸ Dr. R. Jarrar, Mass Analytcs. *Your Comprehensive Marketing Mix Modeling Guide*.

$$ROI = \frac{(ricavi\ incrementali - investimento)}{investimento} \cdot 100$$

dove i ricavi incrementali sono le vendite ottenute dalle variabili incrementali, ovvero comunicazione pubblicitaria e attività promozionali, mentre la differenza *ricavi incrementali – investimento* rappresenta il profitto incrementale.

Inoltre, bisogna sottolineare che, la variabile dipendente del modello è espressa in termini di volumi di vendita, mentre il ROI in termini di valore di vendita. Per il seguente motivo bisogna moltiplicare le vendite incrementali per il prezzo medio del prodotto, in modo da garantire che il ROI sia espresso correttamente in termini monetari.

A livello interpretativo, un ROI del 100% significa che, per ogni euro investito, l'azienda ha generato un euro di profitto netto. Un ROI compreso tra lo 0% e il 100% indica che l'investimento ha generato un profitto, sebbene inferiore all'investimento iniziale. Un ROI dello 0% significa che l'azienda ha recuperato esattamente l'investimento iniziale senza generare profitto né perdita. Infine, un ROI negativo indica una perdita netta sull'investimento³⁹.

In relazione al Ritorno sull'Investimento si collegano le curve di saturazione, con la Teoria dei Rendimenti Decrescenti, che, discussa nella sezione 2.2.2, trova applicazione anche nell'interpretazione dei risultati del modello. Questo poiché un ROI elevato non implica che in un determinato canale che produce buoni rendimenti sia possibile aumentare l'intensità dell'investimento ininterrottamente, dato che il canale raggiungerà il punto di saturazione e gli investimenti inizieranno ad avere rendimenti decrescenti. Ciò consente agli operatori di marketing di massimizzare l'impatto dei loro investimenti, distribuendo le risorse in modo da ottenere il miglior ritorno possibile.

In aggiunta, i Marketing Mix Model permettono di ottenere valutazioni relative esclusivamente alle campagne pubblicitarie, andando a calcolare l'efficacia e l'efficienza dei canali di comunicazione. L'efficacia è una metrica che permette di isolare l'impatto della comunicazione di un singolo canale o campagna. Rappresenta i ricavi incrementali ottenuti in relazione alla copertura mediatica raggiunta ed è così definita:

$$efficacia = \frac{ricavi\ incrementali}{GRPs} \cdot 100 .$$

³⁹ Borsa Italiana. *Glossario finanziario - Return on Investments*. URL <https://www.borsaitaliana.it/borsa/glossario/return-on-investments.html>

L'efficienza, invece, è un indice che delinea quanto la comunicazione pubblicitaria di un determinato canale sta contribuendo alle vendite in relazione al suo investito. L'efficienza è definita come segue:

$$efficienza = \frac{\% \text{ contributo del canale sulle vendite}}{\text{investimento sul canale}} \quad 40.$$

2.5 Limitazioni dei Marketing Mix Model

Come tutti gli strumenti analitici, i Marketing Mix Model presentano vantaggi e limitazioni. Alcuni limiti derivano dall'approccio di modellizzazione scelto, come ad esempio la mancata cattura di effetti pubblicitari quali carryover o sinergie tra canali da parte di modelli lineari e moltiplicativi semplici. Modelli più complessi, d'altra parte, possono presentare difficoltà di calcolo e interpretazione. Oltre a questi, esistono anche limitazioni intrinseche dei Marketing Mix Model stessi⁴¹.

In primo luogo, la qualità dei risultati di un MMM dipende anche dalla qualità dei dati di input, problematica da non sottovalutare, soprattutto per canali digitali che sono in rapida evoluzione. Difatti, fino a pochi anni fa, la raccolta dei dati di questi canali digitali erano di natura aggregata e di bassa qualità. Tale criticità è stata riscontrata anche nella scelta del dataset relativo al caso studio del presente elaborato.

Una seconda limitazione risiede nel fatto che nonostante siano disponibili diversi approcci di modellistica, atti a catturare quante più dinamiche di mercato possibili, in un mondo sempre più digitalizzato, dove i consumatori sono esposti a molteplici punti di contatto con il marchio in esame, gli MMM tradizionali e più semplici possono faticare a rappresentare correttamente queste complesse interazioni, rendendo necessari approcci più complessi come modelli di machine learning e bayesiani.

Ulteriori limitazioni sono dovute dal fatto che gli MMM si basano fortemente su dati storici. Questo può renderli meno efficaci in situazioni di rapido cambiamento del mercato o nel caso di lancio di nuovi prodotti, dove i dati passati potrebbero non essere rappresentativi delle condizioni attuali o future. Oltre a ciò, questi modelli tendono a concentrarsi principalmente sugli effetti a breve termine delle attività di marketing, rendendo plausibile la

⁴⁰ Acceleration, WPP Company. Manuale aziendale.

⁴¹ Cain P. M. (2008). *Limitations of conventional marketing mix modelling*. Admap Magazine, (493), 48-51.

possibilità di sovrastimare l'importanza di attività promozionali che generano vendite immediate, sottovalutando l'impatto a lungo termine di campagne pubblicitarie.

Nonostante tali criticità il Marketing Mix Modeling rimane uno strumento potente ed efficace per la valutazione e ottimizzazione delle strategie di marketing.

3. Caso studio

Appresi i fondamenti del marketing mix modeling esposti nel capitolo precedente, si procede all'applicazione pratica di tali principi a un caso studio reale. L'analisi si concentra sulla quantificazione dell'impatto delle diverse leve di marketing, sia tradizionali che digitali, sulle performance di vendita del prodotto nel mercato italiano, permettendo di identificare i canali più performanti. In particolare, il prodotto in esame appartiene alla linea skincare di un'azienda leader nel settore cosmetico, caratterizzato da una strategia di marketing diversificata che comprende sia media tradizionali, come la televisione, sia canali digitali, come Tik Tok, Meta, Pinterest e Youtube.

L'analisi esposta nel seguente capitolo si articola in quattro sezioni principali. Inizialmente verrà descritto il contesto di analisi, il dataset utilizzato, il periodo temporale, la granularità dei dati e le variabili di interesse. La seconda sezione definisce la metodologia impiegata, motivando la scelta dell'approccio adottato nelle sezioni seguenti. La terza sezione descrive le fasi di calcolo dei parametri di trasformazione delle variabili media, al fine di catturare gli effetti *adstock* e *shape*. I risultati ottenuti saranno funzionali alla fase successiva, nella quale verrà impostata l'equazione del modello più adatto al contesto dell'analisi. All'interno della sezione verranno presentati le performance del modello ritenuto più accurato e la validazione di quest'ultimo. Dopo aver dimostrato la robustezza del modello utilizzato si procede con l'interpretazione dei risultati volti ad usi manageriali, come la scomposizione delle vendite e il calcolo di metriche di interesse quali il Ritorno Sull'Investimento, che faranno parte dell'ultima sezione affrontata.

3.1 Contesto di analisi e dataset

Come già affermato il prodotto in esame fa parte del settore cosmetico e skincare, in particolare del segmento anti-age, essendo i responsabili di acquisto (RA) di tale prodotto le donne over 35. Il medesimo target è stato utilizzato anche per la pianificazione pubblicitaria, i contatti lordi e netti rilevati sono misurati in riferimento alla popolazione femminile italiana over 35.

L'analisi si basa su dati settimanali raccolti nel periodo gennaio 2021 – giugno 2024. Le informazioni di vendita sia a valore che a volume settimanale sono fornite da provider A leader globale nella misurazione e analisi del comportamento dei consumatori e delle performance di vendita. I dati relativi agli investimenti del media e delle performance dell'esposizione pubblicitaria televisiva, espressa in GRP, provengono dalla Media Flow Chart di provider B una delle principali agenzie media a livello mondiale, che traccia l'andamento settimanale delle

campagne TV e non. Per quanto le performance del digital marketing provengono da diverse piattaforme di Google:

- Display & Video 360 (DV360): piattaforma di advertising utilizzata per la gestione e il monitoraggio delle campagne display e video. DV360 fornisce dati sulle impression di diversi formati pubblicitari;
- Search Ads 360 (SA360): piattaforma per la gestione delle campagne search, che fornisce dati granulari sui click generati dalle attività di Search marketing sia su Google che su altri motori di ricerca come Amazon.

Infine, i dati dei competitor del prodotto in esame sono forniti da provider C in modo da garantire una misura completa e accurata della pressione pubblicitaria del mercato.

3.1.1 Presentazione del dataset grezzo

Il dataset grezzo presenta 76 variabili, tra cui performance di vendite, variabili di baseline, variabili media e i dati dei competitor. Di seguito una presentazione delle variabili presenti nel dataset (si veda anche l'elenco in Appendice):

```
> names(df)
[ 1] "Week_Ending"
[ 2] "Vol_Sales"
[ 3] "EUR_Sales"
[ 4] "Average_price"
[ 5] "NEW_DATA_NMR"
[ 6] "EUR_in_Promo"
[ 7] "Volume_in_Promo"
[ 8] "Base_EUR"
[ 9] "Base_Volume"
[10] "Base_price"
[11] "Promo_Intensity"
[12] "SEASONALITY"
[13] "TRADE_VOLANTINI"
[14] "GRP_target"
[15] "GRP_h/c_1"
[16] "GRP_h/c_2"
[17] "Imp_ADRESS"
[18] "Imp_DISPLAY_AMAZON"
[19] "Imp_DISPLAY_GOOGLE"
[20] "Imp_VIDEO_AMAZON"
[21] "Imp_VIDEO_YT"
[22] "Imp_VIDEO_OTHER"
[23] "Imp_META"
[24] "Imp_TIK_TOK"
[25] "Imp_PINTEREST"
[26] "CLICK_Search_Amazon"
[27] "CLICK_Search_Google"
[28] "COMPETITOR_01"
[29] "COMPETITOR_02"
[30] "COMPETITOR_03"
[31] "COMPETITOR_04"
[32] "COMPETITOR_05"
[33] "COMPETITOR_06"
[34] "COMPETITOR_07"
[35] "COMPETITOR_08"
[36] "COMPETITOR_09"
[37] "COMPETITOR_10"
[38] "COMPETITOR_11"
[39] "COMPETITOR_12"
[40] "COMPETITOR_13"
[41] "COMPETITOR_14"
[42] "COMPETITOR_15"
[43] "COMPETITOR_16"
[44] "COMPETITOR_17"
[45] "COMPETITOR_18"
[46] "COMPETITOR_19"
[47] "COMPETITOR_20"
[48] "COMPETITOR_21"
[49] "COMPETITOR_22"
[50] "COMPETITOR_23"
[51] "COMPETITOR_24"
[52] "COMPETITOR_25"
[53] "COMPETITOR_26"
[54] "COMPETITOR_27"
[55] "COMPETITOR_28"
[56] "COMPETITOR_29"
[57] "COMPETITOR_30"
[58] "COMPETITOR_31"
[59] "COMPETITOR_32"
[60] "COMPETITOR_33"
[61] "COMPETITOR_34"
[62] "COMPETITOR_35"
[63] "COMPETITOR_36"
[64] "COMPETITOR_37"
[65] "COMPETITOR_38"
[66] "COMPETITOR_39"
[67] "COMPETITOR_40"
[68] "COMPETITOR_41"
[69] "COMPETITOR_42"
[70] "COMPETITOR_43"
[71] "COMPETITOR_44"
[72] "COMPETITOR_45"
[73] "COMPETITOR_46"
[74] "COMPETITOR_47"
[75] "COMPETITOR_48"
[76] "COMPETITOR_49"
```

Competitor names anonymized in the public version.

Figura 4- lista delle variabili ed elenco dei principali competitor

La variabile temporale “Week_Ending” rappresenta l'ultimo giorno, la domenica, di ogni settimana in osservazione, definendo così la granularità settimanale dei dati, che coprono il periodo da gennaio 2021 a giugno 2024.

Le performance di vendite sono le variabili “Vol_Sales” e “€_Sales”; esse rappresentano rispettivamente le vendite a volume, espresse in unità, e a valore, espresse in euro, del prodotto in analisi. I dati di vendita provengono da diversi canali distributivi: Food (super e ipermercati), Drugstores (catene specializzate), Discounters e E-commerce, fornendo così una copertura completa dei principali canali di vendita del mercato italiano. Queste variabili rappresentano il focus dello studio, il cui obiettivo è determinare quali variabili hanno generato più vendite e valutare l'impatto delle strategie di marketing su di esse.

Altre variabili presenti nell'elenco possono essere classificate secondo le categorie descritte nella sezione 2.1.2. Tra le variabili di baseline rientrano:

- Base_price, indica il prezzo base o stock di vendita dei prodotti, ritenuto più accurato e utile rispetto a “Average_price” che rappresenta il prezzo medio a cui vengono venduti i prodotti, includendo anche l'effetto delle promozioni.
- NEW_DATA_NMR, è il numero di referenze medio, indica la gamma dei formati del prodotto in vendita.
- SEASONALITY, indice di stagionalità, che cattura le fluttuazioni stagionali delle vendite.

Seguono le variabili incrementali, ovvero le leve di marketing direttamente controllabili dalle aziende e si distinguono in promozioni e attività mediatiche.

Oltre ai dati sulle vendite settimanali in promozione a volume e a valore, è disponibile la variabile Promo_Intensity, che sarà inclusa nel modello. Questa variabile rappresenta la percentuale di vendite effettuate in promozione, calcolata come rapporto tra le vendite in promozione (a volume o a valore) e le vendite totali settimanali.

Seguono le performance, in termini di audience, delle attività mediatiche televisive e digitali, relative al prodotto in esame e la pressione pubblicitaria televisiva di due ulteriori prodotti della stessa azienda, appartenenti a linee diverse. Questi ultimi sono stati inclusi nell'analisi per valutare se la loro comunicazione abbia influenzato le vendite del prodotto target, generando effetti halo o di cannibalizzazione (Sezione 2.1.4).

Per concludere le variabili relative alle attività mediatiche vi sono le impression del marketing digitale. Tra i diversi mezzi vi sono YouTube, Meta, Tik Tok e Pinterest. Altre strategie di marketing digitali, sono il Display marketing e il Search marketing, entrambe monitorate sia su Google che Amazon.

Infine, a partire dall'elemento n. 28 della Figura 4, sono elencati i nomi dei maggiori competitor del settore in esame. Per ognuno di essi è presente la distribuzione della pressione pubblicitaria in termini di GRP. Ciò permette di analizzare se la comunicazione effettuata dai competitor abbia effettivamente eroso le vendite del prodotto analizzato.

In conclusione, il dataset nella sua versione grezza presenta un numero elevato di variabili da includere nelle analisi. Per tal motivo sono state effettuate aggregazioni di alcune variabili in modo da rendere più semplice e meno problematica la specificazione del modello. Analisi più granulari sono effettuate in contesto aziendale e a seconda delle esigenze del cliente. L'analisi verrà dunque effettuata sui principali mezzi di comunicazione e strategie di marketing e le aggregazioni verranno effettuate a seconda di criteri risultanti da un'analisi esplorativa delle variabili, mantenendo comunque un elevato potere interpretativo in modo da fornire informazioni rilevanti per dimostrare quali sono le strategie che producono maggiori vendite del prodotto.

Inoltre, verranno selezionate le variabili più rilevanti ai fini dello studio, ciò varrà sia per la variabile dipendente che per le variabili indipendenti. Molte di loro hanno infatti significati simili ma ognuna di essa presenta delle particolarità che conducono ad un'analisi più accurata del fenomeno studiato. Nella prossima sezione seguirà un'analisi accurata del dataset che condurrà a quanto affermato e alla selezione ed aggregazione delle variabili che andranno a comporre l'equazione del modello definitivo.

3.1.2 Selezione delle Variabili

A partire dal dataset iniziale, è stata effettuata una selezione delle variabili più rilevanti per il modello, basata su considerazioni teoriche, analisi preliminari e obiettivi di business.

Come variabile dipendente è stata scelta il volume delle vendite settimanali, in quanto misura direttamente delle performance del prodotto.

Per quanto riguarda le variabili di baseline sono state selezionate:

- Base_Price, poiché è necessaria all'interno del modello una variabile che identifichi il prezzo più puro del prodotto analizzato;
- NEW_DATA_NMR, ovvero, il numero medio di referenze è stata selezionata per valutare come la gamma di formati del prodotto impatta sulle sue vendite, a indicare come la varietà di scelta del prodotto influenza le vendite;
- SEASONALITY, variabile importante per spiegare le fluttuazioni di domanda del prodotto, durante determinati periodi dell'anno.

Seguono le variabili relative alle strategie di marketing vere e proprie. Iniziando da quelle relative alle promozioni si è deciso di includere “promo_intesity”, considerata più rilevante e accurata tra le variabili che monitorano le promozioni. Ciò dovuto dal fatto che più il valore percentuale è elevato, più vendite sono state effettuate sotto promozioni.

Tutte le variabili relative alle attività mediatiche saranno incluse in analisi, ad esclusione di “TRADE_VOLANTINI” E “imp_ADRESS”, giustificate dalla mancanza di osservazioni e metodo di raccolta dati incerto.

Saranno analizzati:

- I GRP del prodotto target;
- GRP di prodotti della stessa linea dell’azienda per valutare effetti halo e/o cannibalization;
- Impression dei social, come Meta, Tik Tok e Pinterest;
- Impression dei video, come Youtube, Amazon e other_video;
- Impression del display marketing monitorato su Google e Amazon;
- Click del Search Marketing su Google e Amazon.

Come si nota dal dataset iniziale vi è un gran numero di competitor nel settore del marchio in studio. Per tal motivo includere tutti questi risulterebbe complesso. A tal fine si è deciso di includere solo i maggiori competitor e quelli più attivi a livello di comunicazione televisiva. Partendo da un totale di 50 competitor presenti nel mercato è stata calcolata l'incidenza percentuale dei GRP di ciascun brand sul totale della comunicazione del settore. Questo ha permesso di identificare i competitor con maggiore presenza mediatica, utilizzando una soglia del 4% di *share of voice* (comunicazione del marchio) come criterio di inclusione, valore che permette di selezionare i marchi più conosciuti sul mercato. Per comprendere meglio il panorama competitivo, la Figura 5 mostra la distribuzione della pressione pubblicitaria, espressa in *share of voice*, per tutti i competitor del settore, escluso il brand in analisi.




Figura 5- share of voice dei competitor

Come si evince dalla Figura 5, su un totale di 50 competitor, la comunicazione è fortemente concentrata in pochi competitor principali. I primi due dominano il panorama pubblicitario, con share of voice rispettivamente del 21,9% e del 14,6%. Si distingue poi un secondo gruppo di quattro competitor che si attesta tra il 4,5% e il 10,9% di share of voice, mentre la restante quota, pari al 35,2%, risulta frammentata tra 43 competitor con share inferiori al 4%.

Sulla base di questi risultati, si è scelto di includere nell'analisi i sette competitor con share of voice superiore al 4,5% (evidenziati in giallo), che complessivamente rappresentano il 64,8% della pressione pubblicitaria del mercato. Per quantificare la pressione competitiva nel modello, è stata quindi creata la variabile “competitors”, calcolata come somma dei GRP di questi sette competitor. Questo permette di confrontare direttamente l'investimento pubblicitario del prodotto in analisi con quello dei suoi principali concorrenti e di valutare l'impatto della pressione competitiva sulle vendite.

3.1.3 Analisi Esplorativa dei Dati

L'analisi esplorativa inizia con l'esame della variabile dipendente, ovvero il volume di vendita settimanale del prodotto analizzato (Vol_Sales). Comprendere l'andamento delle vendite nel tempo e le sue caratteristiche distributive è fondamentale per la successiva modellazione.

La Figura 6 rappresenta la serie temporale delle vendite del prodotto in esame dal 2021 fino a giugno 2024. Si osserva un trend sostanzialmente stazionario delle vendite, con fluttuazioni frequenti e un range che va da 10.000 a 30.000 unità vendute, a indicare un'elevata

variabilità. La stagionalità è evidente, con cali di vendita nei mesi estivi come giugno, luglio e agosto e picchi nei mesi invernali. Questo andamento è coerente con le caratteristiche del prodotto, che risulta più utile durante i mesi invernali. Infine, dal grafico non si notano outlier evidenti.




Figura 6- serie temporale delle vendite a volume

La Tabella 1 riporta le statistiche descrittive della variabile dipendente selezionata. Con una media di 20.343 unità, le vendite mostrano una mediana leggermente inferiore, pari a 19.535 unità. Questa lieve differenza suggerisce una distribuzione leggermente asimmetrica a destra, con una maggiore frequenza di valori superiori alla media. Le vendite minime, pari a 10.403 unità, e le vendite massime, pari a 32.223 unità, delimitano il range osservato, confermando l'ampiezza delle fluttuazioni evidenziate nel grafico della serie temporale (Figura 7). Fattori come promozioni, stagionalità o attività dei competitor potrebbero spiegare questa variabilità e saranno oggetto di approfondimento nelle successive sezioni dell'analisi.

Min.	1st Qu.	mediana	media	3rd Qu.	Max.
10.403	16.701	19.535	20.343	23.947	32.223

Tabella 1- statistiche descrittive vendite a volume

La distribuzione delle vendite settimanali, analizzata tramite l'istogramma in Figura 7, conferma la leggera asimmetria positiva evidenziata dalle statistiche descrittive:




Figura 7- istogramma delle vendite a volume

Si evince una maggiore concentrazione di valori intorno alla mediana e una coda che si estende verso i valori più alti. Difatti la maggior parte delle vendite settimanali si concentra tra 15.000 e 25.000 unità, con il picco di frequenza intorno al valore mediano.

Prima di procedere con l'analisi esplorativa delle variabili indipendenti, è necessario valutare la presenza di correlazioni tra di esse. L'obiettivo di questa analisi è identificare eventuali problemi di multicollinearità, ovvero la presenza di forti correlazioni lineari tra due o più variabili indipendenti. La multicollinearità può rendere difficile l'interpretazione dei coefficienti del modello e ridurre la precisione delle stime. Questo sarà un problema costante durante lo studio, in quanto le variabili di marketing sono in forte relazione tra di loro. Per tal motivo, al fine di evitare tali criticità tra le variabili di input sono state effettuate aggregazioni tali da mantenere sia un potere esplicativo che rimuovere la problematica.




Figura 8- matrice di correlazione

Dalla matrice delle correlazioni (Figura 8) emergono alcuni valori particolarmente elevati, tra cui spicca la correlazione tra `imp_META` e `imp_VIDEO_YT`, pari a 0,76. Questa forte relazione ha rappresentato un elemento critico nella fase di aggregazione delle variabili. L'approccio iniziale prevedeva la creazione di due macro-variabili: una denominata "Social", che avrebbe aggregato Meta, TikTok e Pinterest, e una denominata "Video", che avrebbe incluso Youtube, Amazon e Other Video. Tuttavia, come evidenziato dalle Figure 9 e 10, che mostrano in ordine decrescente la media delle impression per ciascun mezzo, Meta e Youtube emergono come canali dominanti nelle rispettive categorie.




Figura 9- medie della pressione pubblicitaria dei canali social




Figura 10- medie della pressione pubblicitaria dei canali video

Da ciò si evince che un'ipotetica aggregazione per strategia potrebbe riflettere ancora la relazione presente tra Meta e YouTube dato che rappresentano la maggior parte della variabile aggregata. Per ovviare a questa problematica, si è optato per un'aggregazione basata non sulla strategia ma sul livello di penetrazione dei mezzi, creando due variabili: `imp_youtube_meta`, che comprende i canali principali, e `imp_video_social`, che include i canali secondari. Questa scelta, pur mantenendo il potere esplicativo della strategia di marketing, permette di

semplificare significativamente il modello, conducendo a stime più robuste dell'impatto delle variabili analizzate.

La Figura 11 mostra la matrice di correlazione costruita sulle variabili finali, ottenute a seguito dell'aggregazione, che saranno utilizzate nel marketing mix model.




Figura 11- matrice di correlazione

L'aggregazione delle variabili, come mostrato nella Figura 12, ha efficacemente ridotto la correlazione tra le componenti social e video. Nonostante persista una correlazione moderatamente elevata pari a 0,58, tale valore non è considerato problematico per il modello. Analizzando le altre relazioni evidenziate dalla Figura 12, si nota come la stagionalità, rappresentata dalla variabile *seasonal_index_prophet* (variabile ottenuta come descritto più avanti), mostra una forte correlazione positiva, pari a 0,77, con le vendite. Questo risultato, atteso, conferma l'influenza dei fattori stagionali sulla domanda di prodotti skincare. Come evidenziato dal grafico della serie temporale delle vendite (Figura 6), si osserva un calo delle vendite nei mesi estivi, a conferma di questo andamento stagionale. Il prezzo base, *Base_price*, presenta una correlazione negativa con le vendite, con un valore di $-0,26$, coerentemente con la teoria economica secondo cui un prezzo più elevato può ridurre la domanda. Analogamente, il numero medio di referenze, *NEW_DATA_NMR*, mostra una correlazione positiva con le

vendite, con un valore di 0,32, suggerendo che una maggiore varietà di formati del prodotto può stimolare le vendite.

L'intensità promozionale, *Promo_Intensity*, mostra una correlazione moderata con le vendite, con un valore di 0,56, a indicare l'importanza delle promozioni nell'influenzare il volume delle vendite. Per quanto riguarda le attività media, la maggior parte delle variabili presenta correlazioni deboli con le vendite. Fa eccezione la comunicazione televisiva del prodotto in esame, *GRP_target*, che mostra una correlazione moderatamente elevata con un valore di 0,47. Questo suggerisce che la pubblicità televisiva del prodotto potrebbe avere un impatto significativo sulle vendite. La relazione tra la concorrenza, *competition*, e le vendite è negativa, con un valore di -0,12, seppur debole, è un risultato atteso in un contesto competitivo.

Tra le variabili indipendenti, si nota una correlazione moderatamente alta tra la stagionalità e alcune variabili di marketing, come *Promo_Intensity* e i *GRP* televisivi. Questo risultato indica che le strategie di marketing potrebbero tener conto della stagionalità della domanda. Non si osservano infine altre correlazioni di elevata intensità tra le variabili indipendenti.

Conclusa l'analisi delle correlazioni e definite le variabili finali del modello, si prosegue con l'analisi esplorativa delle variabili indipendenti, suddivise per categoria: base, promozionali e media.

Le statistiche descrittive delle variabili di base sono riportate nella Tabella 2.

VARIABILE	MEDIA	MEDIANA	DEV.STD	MINIMO	MASSIMO
NEW_DATA_NMR	10,332	10,558	0,973	8,334	11,807
BASE_PRICE	13,321	13,286	0,726	10,819	14,907
SEASONAL_INDEX_PROPHET	1,000	0,990	0,194	0,659	1,463

Tabella 2 - statistiche descrittive variabili di baseline

La variabile *NEW_DATA_NMR* mostra una media di 10,33 e una deviazione standard relativamente bassa di 0,97. Questo suggerisce che i valori tendono a concentrarsi attorno alla media, con una variabilità limitata. Il range, compreso tra 8,33 e 11,81, conferma questa osservazione. Il prezzo base, *Base_price*, ha una media di 13,32 e una deviazione standard di 0,73. La variabilità del prezzo base è leggermente superiore a quella di *NEW_DATA_NMR*,

indicando una maggiore dispersione dei valori, con un range, da 10,82 a 14,91, il che suggerisce una possibile strategia di prezzo differenziata. A supporto di quanto affermato il boxplot nella Figura 12 mostra i valori minimi della variabile Base_price al di fuori dei baffi.




Figura 12- boxplot Base_price

Al fine di ottenere un indice di stagionalità robusto, si è scelto di utilizzare Prophet, una libreria open-source per analizzare serie temporali sviluppata da Meta⁴².

Prophet, è adatto a contesti di business in cui la domanda è influenzata da fattori stagionali, come si è notato dall'elevata relazione tra la stagionalità e le vendite. La libreria è utilizzata in diversi ambiti, tra cui analisi e previsione della domanda e, come in questo caso, nel marketing mix modeling. Infatti, Prophet trova applicazione anche in strumenti avanzati come Robyn, un pacchetto, anch'esso open source di Meta, per la creazione di marketing mix model basati su IA e machine learning⁴³.

L'indice di stagionalità, `seasonal_index_prophet`, presenta una media pari a 1, come atteso da un indice di stagionalità. Tuttavia, con una deviazione standard di 0,19 e un range tra 0,66 e 1,46,

⁴² URL <https://facebook.github.io/prophet/>

⁴³ URL <https://facebookexperimental.github.io/Robyn/>

si evidenziano significative fluttuazioni stagionali. Un valore di 0,66 corrisponde a un calo delle vendite del 34% rispetto alla media, mentre 1,46 indica un aumento del 46%.




Figura 13 - stagionalità

L'andamento della stagionalità, illustrato nella Figura 13, evidenzia fluttuazioni significative nell'indice `seasonal_index_prophet` nel periodo considerato, dal 2021 al 2024. Si osserva un pattern ciclico che si ripete con cadenza annuale, caratterizzato da un marcato picco verso la fine di ogni anno e un calo pronunciato all'inizio dell'anno successivo. I picchi di stagionalità raggiungono valori superiori a 1,4, indicando un incremento medio delle vendite del 46% rispetto alla media annuale. I cali, invece, toccano valori inferiori a 0,7, corrispondenti a una riduzione media delle vendite del 34%. Questo andamento è coerente con quanto si era notato nella Figura 6 relativa alla serie temporale delle vendite.

Al fine di evidenziare ulteriormente l'andamento della stagionalità, si osserva la Figura 14, che presenta un grafico comparativo delle serie temporali relative alle vendite e all'indice di stagionalità. Dall'analisi del grafico, emerge una notevole sovrapposizione tra i picchi e i cali delle due serie, a conferma della marcata influenza del ciclo stagionale sull'andamento delle vendite. Le discrepanze residue tra le due serie possono essere attribuite all'azione delle altre variabili esplicative considerate nel modello. La significativa presenza di stagionalità, dunque, ne giustifica l'inclusione nel modello, al fine di ottenere stime più accurate dell'impatto delle leve di marketing.




Figura 14- stagionalità vs. vendite

Si prosegue l'analisi esplorativa con la variabile `Promo_Intensity`, relativa alle attività promozionali.

Min	1st Qu.	Median	Mean	3rd Qu.	Max.
0,1065	0,2695	0,3567	0,3618	0,4567	0,6551

Tabella 3- statistiche descrittive `Promo_intensity`

La Tabella 3 mostra le statistiche descrittive della variabile “`promo_intensity`”, come delineato precedentemente tale variabile è derivata dal rapporto tra le unità di vendite effettuate in promozione e le unità di vendite totali. Per tal motivo è una variabile compresa tra 0 e 1 e in particolare l'intervallo di tale variabile è compreso tra 0,1065 e 0,6551, ad indicare un massimo del 65% di vendite effettuate in promozione. Data la forte relazione tra le promozioni e la variabile target, pari a 0,56, risulta interessante visualizzare l'andamento delle promozioni e delle vendite a confronto.




Figura 15- promo_intensity vs. vendite

La Figura 15, nella quale l'andamento delle vendite è confrontato con l'intensità promozionale, evidenzia una relazione complessa tra le due variabili. Si osserva una generale tendenza alla sincronizzazione tra picchi di Promo_Intensity e picchi delle vendite. Ad esempio, i picchi di promozioni all'inizio del 2021, a metà 2022 e verso la fine del 2023 coincidono con i picchi più alti delle vendite. Tuttavia, alcuni cali di vendita, come quello a metà 2021, non sembrano essere direttamente correlati a un aumento di promozioni, indicando l'influenza di altri fattori. Inoltre, l'intensità delle promozioni non sempre si traduce in un aumento delle vendite, o in una riduzione della loro diminuzione. Questa analisi preliminare evidenzia la rilevanza di tale variabile e giustifica la sua inclusione nel modello.

Tra le variabili indipendenti, le attività mediatiche rivestono particolare importanza. Grazie alle fonti dati indicate in precedenza, è stato possibile analizzare direttamente la pressione pubblicitaria, anziché gli investimenti, come avviene in molti modelli di marketing mix. Questa scelta, mirata ad una maggiore accuratezza dell'analisi, prevede la modellizzazione dei dati di pressione pubblicitaria espressi in GRP per la televisione, in Impression per i canali digitali e in click per altre forme di marketing. Per una migliore chiarezza espositiva, l'analisi sarà suddivisa per tipologia di canale.

Segue la Tabella 4 con le statistiche descrittive delle attività mediatiche televisive, che illustra le caratteristiche di queste variabili.

VARIABILE	MIN.	1ST QU.	MEDIANA	MEDIA	3RD QU.	MAX.
GRP	0	0	0	70,12	178,21	311,16
TARGET						
GRP_H/C_1	0	0	0	77,52	184,75	292,93
GRP_H/C_2	0	0	0	37,37	0	284,06

Tabella 4 - statistiche descrittive var. televisive

Le statistiche descrittive riportate nella Tabella 4 riflettono la natura discontinua delle campagne pubblicitarie televisive, caratterizzate dall'alternarsi di periodi di attività e periodi di silenzio. I GRP, che misurano i contatti lordi raggiunti, dipendono direttamente dall'investimento effettuato: campagne con investimenti più elevati tendono a generare maggiore pressione pubblicitaria. L'investimento, a sua volta, influenza diversi fattori che determinano la pressione pubblicitaria, come la posizione dello spot, la scelta del canale televisivo, la fascia oraria di trasmissione e altri elementi strategici. È possibile notare che il minimo di queste variabili è pari a zero, segnalando un'assenza di comunicazione. Questa natura discontinua delle campagne, caratterizzata da periodi di attività e periodi di silenzio, sarà ulteriormente evidenziata dal grafico successivo. Ad esempio, per la pubblicità del prodotto target si nota un impatto massimo di 311,16 GRP. Questo valore rappresenta l'esposizione cumulativa del target alla pubblicità, espressa in punti percentuali. In altre parole, è la somma dei rating puntuali, ovvero la percentuale del target raggiunta da ogni singolo spot, per tutti gli spot trasmessi. Non indica quante volte ciascun individuo ha visto la pubblicità, ma una misura complessiva dell'esposizione del target, combinando la copertura (quante persone hanno visto almeno uno spot) e la frequenza (quante volte in media le persone raggiunte sono state esposte). Questo valore massimo, come si può osservare nella Figura 16, evidenzia un picco di attività pubblicitaria. L'analisi delle altre variabili, incluse per verificare l'effetto alone e cannibalizzazione, riportate in tabella mostra un andamento simile, a conferma di quanto anticipato sulla natura discontinua delle campagne pubblicitarie televisive, che sarà visivamente rappresentata nel grafico a seguire, con massimi rispettivamente di 292,93 e 284,06 GRP.




Figura 16 -distribuzione pressione pubblicitaria televisiva

Si prosegue con l'analisi esplorativa delle variabili relative alle attività mediatiche digitali. La Tabella 5 riporta le statistiche descrittive di queste variabili.

VARIABILI	MIN.	1ST QU.	MEDIANA	MEDIA	3RD QU.	MAX.
IMP_VIDEO_SOCIAL	0	0	32.229	1.628.789	3.235.687	6.995.258
IMP_META_YOUTUBE	0	0	2.389.590	4.656.440	9.121.419	18.841.880
IMP_DISPLAY	0	0	0	561.228	639.900	4.328.255
SEARCH	0	10.018	22.151	26.189	39.969	80.402

Tabella 5- statistiche descrittive var. digitali

Analogamente alle variabili televisive, anche per le variabili digitali il valore minimo è 0, a indicare l'assenza di attività pubblicitaria in alcune settimane. L'andamento discontinuo di tali variabili si può anche osservare nella Figura 17. La variabile `imp_meta_youtube` mostra valori particolarmente elevati, con un massimo di 18.841.880 impression. Questo indica l'importanza strategica di Meta e YouTube per il brand, che investe significativamente in questi canali. La variabile `Search` quantifica i click derivanti dalle attività di Search marketing. I valori osservati sono significativamente inferiori rispetto alle impression delle altre variabili digitali, con un massimo di 80.402 click settimanali. Questa differenza è dovuta alla natura stessa della metrica, che misura le interazioni dirette degli utenti con gli annunci, anziché le semplici visualizzazioni.

Come si può osservare nella Figura 18, gli investimenti in Search marketing sono più continui rispetto agli altri canali digitali, senza periodi di inattività a partire dal 2022.




Figura 17- distribuzione della pressione pubblicitaria digitale




Figura 18- distribuzione del click Search marketing

Nonostante questa analisi preliminare, la comprensione delle variabili mediatiche risulta ancora incompleta. Le loro distribuzioni, come atteso, presentano elevata variabilità e discontinuità. La presenza di campagne di test, caratterizzate da investimenti inferiori e, di conseguenza, da una minore pressione mediatica, contribuisce alla variabilità delle distribuzioni. Inserire le variabili media grezze nel modello potrebbe causare problemi di eteroschedasticità e stime dei coefficienti instabili. Per ovviare a questo problema, si applica la trasformazione Adstock, che tiene conto dell'effetto di saturazione e dell'effetto ritardato della pubblicità, modificando la distribuzione delle variabili mediatiche, attenuando la discontinuità e catturando l'effetto carryover delle campagne. La trasformazione Adstock, applicata alle variabili media, contribuisce a mitigare l'effetto dei picchi di investimento, grazie alla saturazione del canale. I periodi di inattività vengono "riempiti" dall'effetto di ricordo della pubblicità sui consumatori, anche dopo il termine della campagna. Pertanto, la trasformazione Adstock riveste un ruolo fondamentale nei modelli di marketing mix. La metodologia di applicazione di questa trasformazione e la scelta del modello statistico saranno discussi in dettaglio nella sezione successiva. La sezione appena conclusa ha presentato un'analisi descrittiva ed esplorativa di tutte le variabili incluse nello studio, al fine di comprenderne le caratteristiche principali, evidenziare eventuali relazioni e fornire una base solida per le scelte metodologiche discusse nelle sezioni successive.

3.2 Applicazione della metodologia

La costruzione di un marketing mix model presenta diverse sfide metodologiche, tra cui la modellizzazione dell'effetto ritardato della pubblicità e la scelta di una forma funzionale del modello appropriata, soprattutto in presenza di dati complessi in cui vi siano relazioni non lineari. Questo studio ha affrontato tali sfide attraverso un processo iterativo di selezione e valutazione di diverse tecniche, al fine di garantire la robustezza e l'affidabilità dei risultati. In particolare, la complessità del dataset ha richiesto un'attenta valutazione delle scelte metodologiche, evidenziando alcune criticità che hanno guidato l'evoluzione dell'analisi. Ad esempio, la stima di curve di saturazione a 'S' a tre parametri si è rivelata problematica, a causa dell'instabilità delle stime e della difficoltà nel controllare i parametri durante l'ottimizzazione del modello. Questo ha condotto ad un utilizzo delle curve a "C", più semplici da stimare, di cui ne verrà descritto il processo di stima nella sezione dedicata. Analogamente, a causa di problemi di convergenza con l'algoritmo *nls* (*non-linear least squares*), si è optato per il metodo *nlsLM* (*non-linear least squares Levenberg-Marquardt*), più robusto in tali situazioni. La scelta del modello finale è stata guidata da un processo iterativo di valutazione delle

performance e della capacità di catturare le dinamiche di mercato. Questa sezione delinea le scelte metodologiche effettuate, evidenziando le motivazioni che hanno guidato queste decisioni.

3.2.1 Scelta del modello e dell'algoritmo di stima

Come già esposto nella sezione 2.3 dedicata agli approcci di modellizzazione, esistono molteplici approcci volti alla costruzione di un marketing mix model. Quello adottato nel presente studio, è esposto nel paragrafo 2.3.2, ovvero si è applicato un modello di regressione non lineare. In particolare, il modello di regressione non lineare utilizzato è composto da una parte moltiplicativa, comprendente le variabili di baseline, ed una additiva, contenente le variabili relative al marketing:

$$Y = (X_1^{\beta_1} \cdot X_2^{\beta_2}) \cdot (\beta_0 + \beta_3 x_3 + \beta_4 x_4) \cdot \varepsilon$$

L'equazione qui sopra rappresenta una forma base della struttura del modello utilizzato nello studio. La logica dietro tale equazione è stata già illustrata nella sezione 2.3.2. In particolare, la scelta dell'approccio e dell'equazione utilizzata sono giustificati dal fatto che è possibile cogliere diversi effetti delle dinamiche di mercato. Difatti le variabili incluse nella parte moltiplicativa sono le variabili di base, dunque *Base_price*, *seasonality* e *NEW_DATA_NMR*. Queste variabili interagiscono tra di loro determinando il livello base delle vendite. Ad esempio, se la stagionalità è alta e il prezzo è basso, il livello base delle vendite sarà più alto rispetto a una situazione con bassa stagionalità e prezzo alto. Questa parte moltiplicativa non influenza direttamente i coefficienti delle variabili media, ma ne modula l'effetto sulle vendite, amplificandolo o attenuandolo a seconda del livello base delle vendite determinato dalle variabili di baseline. Questo permette di catturare interazioni complesse tra le variabili, che non sarebbero possibili in un modello puramente additivo.

In aggiunta a queste già importate motivazioni, la scelta dell'utilizzo di tale approccio è giustificata anche dalla sua flessibilità. Come discusso in precedenza, uno degli obiettivi del marketing mix modeling, oltre alla scomposizione delle vendite e alla valutazione dell'impatto delle strategie di marketing, è quello di comprendere gli effetti della pubblicità, la sua distribuzione temporale e l'influenza sul consumatore. In particolare, è fondamentale catturare l'effetto ritardato della pubblicità e l'effetto di saturazione, determinando rispettivamente il *decay rate* e il punto di saturazione del canale (Sezione 2.2).

L'approccio non lineare adottato in questo studio consente di stimare i parametri di *decay* e saturazione direttamente durante il processo di ottimizzazione. Questo evita di introdurre potenziali distorsioni nell'analisi derivanti dalla selezione di tali parametri basata esclusivamente su conoscenze pregresse del settore. In modelli tradizionali, lo studio dell'Adstock e della saturazione avviene separatamente dalla modellizzazione, spesso basandosi su valori di default o su parametri considerati standard per il settore.

Tuttavia, l'inclusione di trasformazioni ad hoc, come l'Adstock e le curve di saturazione, in un modello non lineare introduce ulteriore non linearità, aumentando la complessità computazionale e potenzialmente causando problemi di convergenza dell'algoritmo. È quindi fondamentale non solo identificare la forma funzionale più adatta ai dati, ma anche definire la modalità di integrazione di queste trasformazioni nel modello. Tali sfide, e le soluzioni adottate, saranno discusse nella sezione successiva.

In seguito a tali delucidazioni e motivazioni dell'approccio scelto, viene presentata la struttura dell'equazione del modello, esclusa la parte relativa alle variabili mediatriche.

$$Vol_sales = (seasonal_index_prophet^{c_stag}) \cdot (Base_price^{c_base_price}) \cdot (NEW_DATA_NMR^{c_ref}) \cdot (intercetta + c_promo \cdot Promo_Intensity).$$

Da tale equazione si evince che le variabili di base, inserite nella componente moltiplicativa del modello sono: l'indice di stagionalità calcolato mediante Prophet (*seasonal_index_prophet*), il prezzo base (*Base_price*) e il numero di referenze del prodotto analizzato (*NEW_DATA_NMR*). La componente additiva, che include l'intercetta, in questa prima versione del modello considera esclusivamente l'effetto delle promozioni (*Promo_Intensity*). L'intercetta rappresenta il livello base delle vendite in assenza di promozioni. Già in questa forma semplificata, il modello è in grado di catturare interazioni tra le variabili, l'effetto di una promozione, ad esempio, può essere amplificato o attenuato a seconda della stagionalità o del prezzo base.

Per la stima dei parametri del modello non lineare, è stata scelta la funzione *nlsLM* in R. Tale funzione, basata sull'algoritmo di Levenberg-Marquardt (LM), offre un buon compromesso tra velocità di convergenza e robustezza, ed è più robusta rispetto alla funzione *nls*. Inizialmente, è stato utilizzato l'algoritmo *nls*, ma, a causa di problemi di non convergenza dell'algoritmo e convergenza relativa, si è optato per *nlsLM*, che si è dimostrato più robusto in presenza della forte non linearità introdotta dalla trasformazione Adstock e dalle curve di saturazione.

Inoltre, i coefficienti del modello sono stati inizializzati con valori specifici e vincolati all'interno di un range; questi limiti inferiori e superiori aiutano a controllare il processo di ottimizzazione e a evitare stime irrealistiche dei coefficienti. L'algoritmo, quindi, parte dai valori iniziali specificati e li aggiusta iterativamente per minimizzare la differenza tra i valori predetti dal modello e i valori osservati.

3.3 Modellizzazione delle variabili mediatriche

Per modellizzare gli effetti di carryover e shape delle variabili media, e stimare direttamente i parametri di *decay* e saturazione all'interno del processo di ottimizzazione del modello, è stata implementata una funzione *Adstock* personalizzata. Questo approccio analitico consente di determinare i parametri ottimali in modo empirico, basandosi sui dati, a differenza dei metodi tradizionali che spesso si basano su valori predefiniti o derivati da analisi separate. La funzione *Adstock* utilizzata è la seguente:

```
Adstock_SatDecay1 <- function(df_shifted, alpha, decay)
{
  vett_finale <- (df_shifted$NoShift)^alpha+
  decay * (df_shifted$Shift1)^alpha+
  decay^2 * (df_shifted$Shift2)^alpha+
  decay^3 * (df_shifted$Shift3)^alpha+
  decay^4 * (df_shifted$Shift4)^alpha+
  decay^5 * (df_shifted$Shift5)^alpha+
  decay^6 * (df_shifted$Shift6)^alpha
  return(vett_finale)
}
```

La funzione calcola l'effetto della pubblicità nel tempo, applicando un *Adstock* geometrico definito dal parametro *decay*. Questo viene moltiplicato alla variabile media shiftata elevata ad un parametro *alpha* che genera una curva di risposta a forma di “C”. In particolare, valori di *alpha* inferiori a 1 producono una curva concava, che rappresenta un effetto di saturazione: all'aumentare della pressione pubblicitaria, l'incremento delle vendite tende a diminuire.

Inoltre, il *df_shifted*, rappresenta un data frame contenente le variabili media “shiftate”, ossia alle quali viene applicato un lag temporale che in questo caso è pari a 6 settimane, ad indicare il periodo ipotetico di ricordo della pubblicità. Questo spiega il motivo per il quale il *decay rate* è elevato ad un'esponente, che indica il lag a cui fa riferimento, ciò in modo tale che il parametro di ricordo si riduca sempre di più sino alla sesta settimana, dopo la quale cesserà, ipoteticamente, l'effetto pubblicitario sui consumatori.

Il data frame delle variabili shiftate è ottenuto dalla seguente funzione:

```

shift_df <- function(vettore, step)
{
  dati_shifted <- data.frame(matrix(0, length(vettore), step + 1))
  names(dati_shifted) <- c('NoShift', paste0('Shift', 1:step))
  for(i in 0:(step))
  {
    if(i == 0) dati_shifted[, 1] <- vettore
    else
    {
      dati_shifted[-(1:i), i+1] <- vettore[1:(length(vettore)-i)]
    }
  }
  return(dati_shifted)
}

```

La funzione `shift_df` riceve in input un vettore con i valori della variabile media e restituisce un dataframe con il vettore originale e le sue versioni shiftate, rappresentate da Shift1, Shift2, ..., Shift6.

Per rendere più evidenti le operazioni descritte si consideri il seguente esempio effettuato sulla variabile `imp_meta_youtube`:

```

> head(df$imp_meta_youtube)
[1] 3273810 1589472 7664398 8523079 10208257 9072714

```

così è come si presenta la distribuzione della variabile `imp_meta_youtube` prima dello shift;

```

> head(imp_meta_youtube_shift)
  NoShift  Shift1  Shift2  Shift3  Shift4  Shift5  Shift6
1 3273810      0      0      0      0      0      0
2 1589472 3273810      0      0      0      0      0
3 7664398 1589472 3273810      0      0      0      0
4 8523079 7664398 1589472 3273810      0      0      0
5 10208257 8523079 7664398 1589472 3273810      0      0
6 9072714 10208257 8523079 7664398 1589472 3273810      0

```

così è come si presenta la stessa variabile dopo aver applicato lo shift.

Unendo la trasformazione Adstock geometrica e il lag temporale a livello teorico si ottiene:

$$adstock(x_{m,t} | w_m, L) = \sum_{l=0}^L w_m(l) x_{m,t-l} \text{ con } w_m(l; \alpha_m^l) = \alpha_m^l \text{ e } 0 < \alpha_m < 1$$

e:

$$adstock(x; \alpha_m^l) = X_{shift} \cdot \alpha = \begin{bmatrix} x_1 & 0 & 0 & \dots & 0 \\ x_2 & x_1 & 0 & \dots & 0 \\ x_3 & x_2 & x_1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_n & x_{n-1} & x_{n-2} & \dots & x_{n-t} \end{bmatrix} \cdot \begin{pmatrix} 1 \\ \alpha \\ \alpha^2 \\ \vdots \\ \alpha^l \end{pmatrix}$$

Il processo di stima di tali parametri ha presentato diverse criticità, la principale è stata la relazione che vi è fra alcuni parametri del modello. In particolare, Alpha e decay sono strettamente legati tra loro e per stimare tali parametri della trasformazione Adstock è stato adottato un approccio strutturato che prevede la stima di modelli separati per ciascuna variabile media. Questa scelta, motivata dalla necessità di evitare problemi di forti legami tra i parametri e di semplificare il processo di stima, consente un maggiore controllo sui parametri di ogni singola variabile, tuttavia con la limitazione di non stimare tutti i parametri contemporaneamente all'interno dello stesso modello, perdendo così potenziali interazioni tra le variabili mediatriche.

Per ogni variabile media, è stato, quindi, costruito un modello di regressione non lineare, la cui equazione generale del modello è la seguente:

$$Vol_Sales = (seasonal_index_prophet^{c_{stag}}) \cdot (Base_price^{c_{base_price}}) \cdot (NEW_DATA_NMR^{c_{ref}}) + (intercetta + Promo_Intensity \cdot c_{promo}) + Adstock_SatDecay1(Variabile_Media_Shiftata, alpha, decay)$$

È importante evidenziare che questi modelli individuali non includono un coefficiente di impatto per la variabile media trasformata, dato che l'obiettivo è esclusivamente quello di stimare i parametri *alpha* e *decay*, non di quantificare l'impatto della variabile media sulle vendite. Quest'ultimo sarà valutato nel modello completo, dove tutte le variabili media trasformate saranno incluse con i loro rispettivi coefficienti di impatto.

Di seguito è riportato il modello utilizzato per la stima dei parametri della variabile “imp_meta_youtube”, una delle strategie marketing di punta del prodotto in analisi, la cui struttura è stata replicata per tutte le altre variabili media:

```
modello_nlsLM_meta_youtube <- nlsLM(
  formula = Vol_Sales ~
    (seasonal_index_prophet ^ c_Stag) *
    (log(Base_price) ^ c_base_price) *
    (NEW_DATA_NMR ^ c_ref) *
    (intercetta + c_promo * Promo_Intensity) +
    Adstock_SatDecay1(imp_meta_youtube_shift, alpha_meta_yt, decay_meta_yt) ,
  data = df,
  start = start_values,
  lower = lower_bounds,
  upper = upper_bounds,
  control = nls.lm.control(maxiter = 1000, ftol = 1e-8)
)
```

Dal blocco di codice sopra riportato si evidenzia l'utilizzo dell'algoritmo *nlsLM*. Come discusso in precedenza, l'equazione del modello non include coefficienti che misurano direttamente l'impatto della variabile sulle vendite.

Si noti la trasformazione logaritmica applicata alla variabile `Base_price`. Questa trasformazione è stata introdotta per ridurre l'influenza degli outlier evidenziati dal boxplot (Figura 13) nell'analisi esplorativa, rendendo il modello meno sensibile a valori estremi. Poiché questi outlier rappresentano diverse strategie di prezzo e non essendo eccessivamente anomali, si è scelto di mantenerli nell'analisi, ponendo attenzione al rispetto dell'ipotesi di omoschedasticità dei residui.

In seguito, si osservano le liste `start`, `lower` e `upper`. Queste contengono rispettivamente i valori iniziali, i limiti inferiori e superiori dei parametri del modello. L'impostazione di questi valori è fondamentale per garantire la convergenza dell'algoritmo *nlsLM* e per ottenere stime plausibili dei parametri. Definire limiti inferiori e superiori aggiunge ulteriore controllo al modello, non solo evitando stime irrealistiche in un contesto di business, ma anche a livello computazionale. I valori iniziali e i limiti per i parametri del modello sono presentati nel seguente blocco di codice:

```
coeffs <- as.data.frame(list(
  c_Stag = c(1, 0.5, 1.2),
  c_base_price = c(-0.8, -3, -0.4),
  c_ref = c(1.5, 0, 2.3),
  intercetta = c(mean(df$Vol_Sales) * 0.8,
                  mean(df$Vol_Sales) * 0.5,
                  Inf),
  c_promo = c(14000, 10000, Inf)
))
```

Questi valori sono il risultato sia di conoscenze pregresse del settore sui valori tipici che i coefficienti di determinate variabili dovrebbero assumere, sia di diverse iterazioni volte a trovare i valori che meglio si adattano alla struttura del modello e alla natura dei dati.

L'intercetta, il cui range si aggira intorno alla media del volume delle vendite, rappresenta il livello base delle vendite in assenza di effetti delle variabili nella parte additiva del modello. Il limite superiore dell'intercetta viene lasciata a "Inf" dato che non genera particolari problemi computazionali.

Per quanto riguarda le promozioni, tendenzialmente vengono lasciate piuttosto libere. Infatti, la scelta di un limite superiore pari a infinito riflette il forte impatto che queste possono avere sulle vendite.

Per le variabili della parte moltiplicativa, invece, tra cui la stagionalità, si ha un range di valori che va dal determinare un effetto smorzato della stagionalità, con un coefficiente pari a 0,5, ad uno amplificato, con un valore di 1,2. Il coefficiente del prezzo base è vincolato a valori negativi, coerentemente con l'aspettativa che un aumento del prezzo determini una diminuzione delle vendite. Al contrario, il coefficiente relativo al numero di referenze ha valori iniziali positivi, riflettendo l'ipotesi che una maggiore disponibilità di formati diversi del prodotto sia associata a un aumento delle vendite.

È possibile notare che, per questo modello utilizzato per stimare i parametri di trasformazione delle Impression di YouTube e Meta, non sono stati mostrati i valori iniziali di *alpha* e *decay*. Questi coefficienti, infatti, sono stati inizializzati in accordo con la teoria, assumendo valori compresi tra 0 e 1. Si ricorda che, per ottenere una curva di saturazione concava il parametro *alpha* deve essere minore di uno.

```
> summary(modello_nlsLM_meta_youtube)

Formula: Vol_Sales ~ (seasonal_index_prophet^c_Stag) * (log(Base_price)^c_base_price) *
  (NEW_DATA_NMR^c_ref) * (intercetta + c_promo * Promo_Intensity) +
  Adstock_SatDecay1(imp_meta_youtube_shift, alpha_meta_yt,
    decay_meta_yt)

Parameters:
      Estimate Std. Error t value Pr(>|t|)
c_Stag      7.050e-01  6.405e-02  11.007  < 2e-16 ***
c_base_price -2.785e+00  4.412e-01  -6.311  2.30e-09 ***
c_ref       7.578e-01  1.041e-01   7.282  1.15e-11 ***
intercetta   3.798e+04  1.840e+04   2.064  0.04050 *
c_promo     2.349e+04  1.236e+04   1.901  0.05904 .
alpha_meta_yt 4.116e-01  2.730e-02  15.074  < 2e-16 ***
decay_meta_yt 6.185e-01  1.991e-01   3.107  0.00221 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2494 on 171 degrees of freedom

Number of iterations to convergence: 10
Achieved convergence tolerance: 1.49e-08
```

I risultati del primo modello stimato sono riportati sopra. L'algoritmo ha raggiunto la convergenza in dieci iterazioni, un buon risultato considerando la bassa soglia di tolleranza impostata. Tutti i coefficienti delle variabili (ad eccezione di *c_promo*), inclusi i parametri di trasformazione *alpha* e *decay*, risultano significativi al livello dello 0,05. Questi ultimi sono plausibili dal punto di vista del business, indicando che il modello ha correttamente catturato l'effetto delle variabili e ha prodotto stime stabili. Inoltre, nessun coefficiente raggiunge i limiti inferiori e superiori imposti, a conferma della correttezza degli intervalli definiti per i parametri.

Le variabili nella componente moltiplicativa del modello hanno associate coefficienti con p-value molto prossimi a zero, un risultato che varrà per tutti i modelli presenti in questo studio. Contrariamente, la componente additiva, presenta risultati più instabili. In particolare, è possibile notare che il coefficiente delle promozioni non è significativo al livello dello 0,05. Un risultato piuttosto inaspettato data l'evidente relazione tra vendite e promozioni evidenziata durante l'analisi esplorativa. Il problema verosimilmente deriva dalla pluralità di relazioni non lineari fra variabili, come tipicamente avviene nella costruzione dei marketing mix model. Tale problematica potrebbe riflettersi non solo sul coefficiente delle promozioni, ma anche sui parametri di decay e alpha, data la forte relazione presente tra di essi, come evidenziato dalla matrice dei coefficienti di correlazione associata alle stime dei parametri nel modello.

```
> print(cor_matrix)
      c_Stag c_base_price      c_ref intercetta      c_promo alpha_meta_yt decay_meta_yt
c_Stag      1.0000000      0.2137062 -0.11686012 -0.0852926 -0.310677398 -0.16663634  0.207963422
c_base_price 0.2137062      1.00000000  0.01454271 -0.8499278 -0.845030485 -0.26474610  0.075644848
c_ref       -0.1168601  0.01454271      1.00000000 -0.5299984 -0.415706008 -0.06226293  0.050548551
intercetta  -0.0852926 -0.84992777 -0.52999843      1.00000000  0.896864086  0.26046503 -0.125250312
c_promo     -0.3106774 -0.84503048 -0.41570601  0.8968641      1.000000000  0.17824443 -0.009008214
alpha_meta_yt -0.1666363 -0.26474610 -0.06226293  0.2604650  0.178244433      1.00000000 -0.722177141
decay_meta_yt 0.2079634  0.07564485  0.05054855 -0.1252503 -0.009008214 -0.72217714      1.000000000

> print(high_correlations)
      Var1      Var2 Correlation
1  intercetta c_base_price -0.8499278
2    c_promo c_base_price -0.8450305
4    c_promo  intercetta  0.8968641
7 decay_meta_yt alpha_meta_yt -0.7221771
```

Le matrici di correlazione riportate sopra confermano le ipotesi iniziali. In particolare, si osserva un'elevata correlazione tra gli stimatori dell'intercetta, del coefficiente delle promozioni e quello del coefficiente del prezzo base, così come tra gli stimatori dei parametri decay e alpha. Per mitigare il problema della collinearità fra gli stimatori dei parametri durante l'ottimizzazione, si è scelto di fissare il valore di uno dei parametri con stimatore più altamente correlato ad uno degli altri stimatori. Sulla base di questo criterio si è scelto di tenere fisso il valore dell'intercetta alla stima ottenuta pari a 37.980. In tal modo si è ottenuto:

```

> summary(modello_nlsLM_meta_youtube)

Formula: Vol_Sales ~ (seasonal_index_prophet^c_Stag) * (log(Base_price)^c_base_price) *
  (NEW_DATA_NMR^c_ref) * (37980 + c_promo * Promo_Intensity) +
  Adstock_SatDecay1(imp_meta_youtube_shift, alpha_meta_yt,
    decay_meta_yt)

Parameters:
      Estimate Std. Error t value Pr(>|t|)
c_Stag      7.050e-01  6.363e-02  11.079  < 2e-16 ***
c_base_price -2.785e+00  2.318e-01 -12.013  < 2e-16 ***
c_ref        7.578e-01  8.799e-02   8.612  4.44e-15 ***
c_promo      2.349e+04  5.451e+03   4.309  2.75e-05 ***
alpha_meta_yt 4.116e-01  2.628e-02  15.659  < 2e-16 ***
decay_meta_yt 6.185e-01  1.969e-01   3.141  0.00199 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2486 on 172 degrees of freedom

Number of iterations to convergence: 8
Achieved convergence tolerance: 1.49e-08

```

Si evince che il fissare l'intercetta al valore precedentemente stimato ha portato ad un aumento generale della stabilità del modello, senza modificare il valore dei coefficienti.

Sebbene questi modelli abbiano il solo scopo di stimare i parametri di trasformazione delle variabili media, si riportano di seguito alcuni risultati a supporto della loro validità. In particolare, il modello per Meta e YouTube presenta un R^2 pari a 0,758, indicando che le variabili di base, le promozioni e la spesa pubblicitaria su questi canali spiega circa il 76% della varianza delle vendite. La Figura 19 dei residui vs. i valori previsti mostra una buona dispersione dei residui, senza pattern evidenti.




Figura 19- grafico residui vs. valori previsti

L'assenza di outlier estremi e la distribuzione dei residui suggeriscono l'omoschedasticità del modello, supportata anche dal test di Breusch-Pagan:

```
> bptest(residuals(modello_nlsLM_meta_youtube) ~ fitted(modello_nlsLM_meta_youtube))

studentized Breusch-Pagan test

data:  residuals(modello_nlsLM_meta_youtube) ~ fitted(modello_nlsLM_meta_youtube)
BP = 1.4333, df = 1, p-value = 0.2312
```

Risultati analoghi, in termini di R^2 , dispersione dei residui e omoschedasticità, sono stati ottenuti anche per i modelli relativi alle altre variabili media.

Dopo aver delineato il metodo di stima, si riportano nella Tabella 6 i valori stimati dei parametri di trasformazione *alpha* e *decay*, con i relativi p-value, per ciascuna variabile media.

VARIABILI	ALPHA	P-VALUE	DECAY	P-VALUE
GRP TARGET	0,9000	0,0354	0,9000	0,0294
GRP_H/C_1	0,9000	0,0304	0,9000	0,0400
GRP_H/C_2	0,9000	0,0939	0,9000	0,0749

IMP_VIDEO_SOCIAL	0,4210	< 0,001	0,4603	0,1125
IMP_META_YOUTUBE	0,4120	< 0,001	0,6190	0,0020
SEARCH	0,5990	<0,001	0,5187	0,0341
IMP_DISPLAY	0,3000	--	0,3000	--
COMPETITION	0,9000	<0,001	0,8400	0,0010

Tabella 6- parametri *alpha* e *decay* stimati

L'analisi dei parametri di trasformazione stimati rivela una netta distinzione tra i valori relativi alla televisione e quelli relativi ai canali digitali. Le variabili televisive presentano valori elevati sia per *alpha* che per *decay*, entrambi pari a 0,9, indicando una saturazione lenta del canale e un effetto di ricordo della pubblicità più duraturo. Al contrario, le variabili digitali mostrano valori più bassi, indicando una saturazione più rapida e un effetto di ricordo meno duraturo.

Per i competitor, invece, si hanno dei valori di *alpha* e *decay* elevati, poiché è stata aggregata la comunicazione televisiva di sette competitor del marchio in analisi, riflettendo quindi le medesime dinamiche riscontrate per i parametri stimati delle variabili televisive. In generale i valori sono plausibili in un contesto di business e in accordo con gli standard del settore. Infatti, nell'analisi degli effetti Adstock e dei rendimenti decrescenti, è comune utilizzare valori più elevati per la televisione, assumendo un impatto più duraturo, e valori più bassi per il digitale, caratterizzato da una comunicazione più veloce e aggressiva. I parametri di trasformazione per la variabile Display non sono stati stimati direttamente dal modello, a causa dell'instabilità delle curve ottenute, probabilmente dovuta dalla limitata variabilità e al numero ridotto di osservazioni disponibili per questa variabile, che hanno reso difficile la stima di parametri complessi. Pertanto, per la trasformazione della variabile Display, si è optato per l'utilizzo di valori standard del settore, al fine di evitare l'utilizzo di stime inaffidabili ed irrealistiche.

Inoltre, si osserva che i parametri per GRP_h/c_2 non sono significativi, con p-value rispettivamente pari a 0,0939 e 0,0749, così come il parametro di *decay* per le impression dei video_social è risultato non significativo. Tuttavia, considerando che l'obiettivo di questa fase è la stima di parametri di trasformazione e non la valutazione del loro impatto sulla variabile dipendente, e dato che i valori ottenuti sono in linea con gli standard del settore, si è deciso di adottare comunque questi valori per la trasformazione delle variabili media.

Si procede infine con la trasformazione vera e propria delle variabili media con i valori stimati applicando la funzione *Adstock_SatDecay1* descritta in precedenza:

```
# Trasformazione delle variabili
df$GRP_target_transformed <- Adstock_SatDecay1(GRP_target_shift , alpha = 0.9, decay = 0.9)
df$GRP_hc_1_transformed <- Adstock_SatDecay1(GRP_hc_1_shift , alpha = 0.9, decay = 0.9)
df$GRP_hc_2_transformed <- Adstock_SatDecay1(GRP_hc_2_shift , alpha = 0.9, decay = 0.9)
df$video_social_transformed <- Adstock_SatDecay1(imp_video_social_shift, alpha = 0.421, decay = 0.4603)
df$meta_youtube_transformed <- Adstock_SatDecay1(imp_meta_youtube_shift, alpha = 0.412, decay = 0.619)
df$search_transformed <- Adstock_SatDecay1(click_search_shift, alpha = 0.5990, decay = 0.5187)
df$competitors_transformed <- Adstock_SatDecay1(competitors_shift, alpha = 0.9, decay = 0.84)
df$display_trasformed<- Adstock_SatDecay1(imp_display_shift, alpha = 0.3, decay = 0.3)
```

Per valutare l'effettiva trasformazione Adstock, sono riportati i grafici delle distribuzioni delle pressioni pubblicitarie televisive e digitali in modo da osservare le differenze con i medesimi grafici riportati nell'analisi esplorativa delle variabili media grezze.




Figura 20- distribuzione della pressione pubblicitaria televisiva trasformata




Figura 21-distribuzione della pressione pubblicitaria digital trasformata




Figura 22- distribuzione della pressione pubblicitaria trasformata dei competitor e del Search marketing

È possibile osservare una sostanziale differenza tra i grafici che figurano la pressione pubblicitaria prima e dopo la trasformazione. Si visualizza come i periodi di inattività siano

stati ridotti dal ricordo della pubblicità, contribuendo a mitigare la discontinuità che le distribuzioni presentavano in precedenza. Analizzando i grafici è possibile notare la differenza del parametro *decay* tra la comunicazione televisiva e quella digitale, per la seconda, infatti, il ricordo decade molto più velocemente, evidenziando delle code molto più ripide per le campagne pubblicitarie digitali.

3.4 Modello finale e risultati

Dopo aver raggiunto uno degli obiettivi più importanti dei marketing mix model, dunque aver catturato gli effetti della pubblicità con l'Adstock e l'effetto dei rendimenti decrescenti, il passo successivo è valutare l'impatto delle variabili di marketing sulle vendite. A tal fine, si utilizza il seguente modello:

$$\begin{aligned} Vol_sales = & (seasonal_index_prophet^{c_stag}) \cdot (\log(Base_price)^{c_base_price}) \cdot \\ & ((NEW_DATA_NMR^{0.5})^{c_ref}) \cdot (intercetta + c_promo \cdot Promo_intensity) + \\ & c_target \cdot GRP_target_trasformed + c_hc_1 \cdot GRP_hc_1_trasformed + c_hc_2 \cdot \\ & GRP_hc_2_trasformed + c_display \cdot display_trasformed + c_meta_youtube \cdot \\ & meta_youtube_trasformed + c_video_social \cdot video_social_trasformed + c_search \cdot \\ & search_trasformed + c_competitors \cdot competitors_trasformed \end{aligned}$$

che risulta implementato in R con la seguente sintassi:

```
modello_nlsLM_complete1 <- nlsLM(
  formula = df$Vol_Sales ~
    (seasonal_index_prophet ^ c_Stag) * (log(df$Base_price) ^ c_base_price) *
    (I(NEW_DATA_NMR^0.5) ^ c_ref) * (intercetta + c_promo * df$Promo_Intensity) +
    c_target * df$GRP_target_transformed + c_hc_1 * df$GRP_hc_1_transformed +
    c_hc_2 * GRP_hc_2_transformed + c_display * df$display_trasformed +
    c_meta_youtube * df$meta_youtube_transformed + c_video_social * df$video_social_transformed +
    c_search * search_trasformed + c_competitors * competitors_trasformed

  data = df,
  start = start_values,
  lower = lower_bounds,
  upper = upper_bounds,
  control = nls.lm.control(maxiter = 1000, ftol = 1e-8)
)
```

La struttura di questo modello è simile a quella utilizzata per stimare i parametri *alpha* e *decay* delle variabili media, con la differenza principale che, in questo caso, le variabili media sono già state trasformate utilizzando i parametri stimati nella sezione

precedente. Un tentativo iniziale di stimare un modello completo, includendo tutte le trasformazioni Astock direttamente nell'equazione, ha portato a un modello instabile a causa dell'elevata multicollinearità e della difficoltà di convergenza dell'algoritmo di ottimizzazione. Pertanto, si è optato per un approccio in due fasi, prima la trasformazione delle variabili media, affrontato nella sezione precedente, e poi la valutazione del loro impatto sulle vendite, permettendo di ottenere stime più stabili e affidabili. Ad evidenza di quanto affermato, nell'equazione del modello si nota la presenza dei coefficienti associati alle variabili media trasformate, che permettono di misurare l'impatto di queste variabili sulla variabile target.

Data l'importanza in un contesto di business, nel modello finale sono state valutate ulteriori trasformazioni, oltre a quella logaritmica già applicata ai modelli in precedenza, volte a migliorare la stabilità e validità statistica del modello, senza compromettere eccessivamente la metrica e l'interpretabilità dei risultati. In particolare, le trasformazioni mirano a ottimizzare diversi aspetti, tra cui la stabilità delle stime dei parametri e la validazione del modello.

Nell'equazione appena presentata, si nota la variabile NEW_DATA_NMR elevata a 0,5. Questa scelta è motivata da una distribuzione che presenta picchi in corrispondenza dei valori 9 e 11; assumendo una forma bimodale, dunque, si opera in modo tale da mitigare l'influenza di questi picchi, migliorando la stabilità del modello anche in fase di validazione. Questa operazione influenzerà positivamente non solo la stabilità del modello, ma anche la fase di validazione.

```
> summary(modello_nlsLM_completo1)
```

```
Formula: df$Vol_Sales ~ ((seasonal_index_prophet^c_Stag) * (log(df$Base_price)^c_base_price) *
(I(NEW_DATA_NMR^0.5)^c_ref)) * (intercetta + c_promo * df$Promo_Intensity) +
c_target * df$GRP_target_transformed + c_hc_1 * df$GRP_hc_1_transformed +
c_hc_2 * df$GRP_hc_2_transformed + c_display * df$display_transformed +
c_meta_youtube * df$meta_youtube_transformed + c_video_social *
df$video_social_transformed + c_search * search_transformed +
c_competitors * competitors_transformed
```

Parameters:

	Estimate	Std. Error	t value	Pr(> t)	
c_Stag	6.281e-01	6.983e-02	8.994	5.42e-16	***
c_base_price	-3.305e+00	5.315e-01	-6.218	3.98e-09	***
c_ref	1.739e+00	2.577e-01	6.749	2.41e-10	***
intercetta	4.069e+04	2.230e+04	1.825	0.06985	.
c_promo	3.967e+04	2.371e+04	1.674	0.09612	.
c_target	2.477e+00	1.629e+00	1.520	0.13032	
c_hc_1	1.211e+00	1.623e+00	0.746	0.45662	
c_hc_2	-1.987e+00	2.020e+00	-0.984	0.32664	
c_display	7.470e-01	5.875e-01	1.272	0.20533	
c_meta_youtube	1.306e+00	4.909e-01	2.660	0.00857	**
c_video_social	1.782e-01	6.626e-01	0.269	0.78834	
c_search	8.494e-01	4.511e-01	1.883	0.06145	.
c_competitors	-2.039e+01	4.611e+00	-4.422	1.76e-05	***

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 2342 on 165 degrees of freedom
```

```
Number of iterations to convergence: 17
```

```
Achieved convergence tolerance: 1.49e-08
```

Dai risultati di questo primo modello finale è possibile notare il persistere del problema precedentemente mostrato della collinearità presente tra gli stimatori dei coefficienti di *c_base_price* e di *c_promo* e dell'intercetta, come si osserva dalla seguente matrice di correlazione.

```
> print(cor_matrix)
              c_Stag      c_ref c_base_price intercetta  c_promo
c_Stag      1.00000000 -0.14441732  0.18791286 -0.02698354 -0.2340666
c_ref       -0.14441732  1.00000000 -0.06224119 -0.55440095 -0.4425744
c_base_price 0.18791286 -0.06224119  1.00000000 -0.78699873 -0.8327528
intercetta  -0.02698354 -0.55440095 -0.78699873  1.00000000  0.9320629
c_promo     -0.23406660 -0.44257444 -0.83275279  0.93206294  1.0000000
```

Tuttavia, prima di procedere adottando il medesimo approccio del modello mostrato per la stima dei parametri di trasformazione, è necessario verificare l'assenza di forti correlazioni fra gli stimatori dei nuovi elementi aggiunti del modello finale: i coefficienti d'impatto.

```
> print(cor_media)
      c_target  c_hc_1  c_hc_2  c_display c_meta_youtube c_video_social  c_search c_competitors
c_target      1.00000000 -0.09884972 -0.038705568 -0.24518099  0.06006856  0.103333364 -0.10612713 -0.27866568
c_hc_1       -0.09884972  1.00000000 -0.309404040 -0.15486714  0.22508431 -0.209196114 -0.04144811  0.06278623
c_hc_2       -0.03870557 -0.30940404  1.000000000 -0.30982178  -0.54890439  0.003036332  0.08973224  0.09136393
c_display    -0.24518099 -0.15486714 -0.309821777  1.00000000  -0.06747551  0.154583355 -0.01743232 -0.09167929
c_meta_youtube 0.06006856  0.22508431 -0.548904394 -0.06747551  1.00000000  -0.542077257  0.01875907 -0.11355520
c_video_social 0.10333336 -0.20919611  0.003036332  0.15458335  -0.54207726  1.000000000 -0.23305497 -0.21789539
c_search     -0.10612713 -0.04144811  0.089732237 -0.01743232  0.01875907 -0.233054970  1.00000000  0.02923359
c_competitors -0.27866568  0.06278623  0.091363926 -0.09167929 -0.11355520 -0.217895394  0.02923359  1.00000000
```

Visualizzando la matrice di correlazione che riguarda gli stimatori dei coefficienti d'impatto non si evidenziano valori elevati che potrebbero portare ad eventuali criticità.

L'equazione del modello dopo aver fissato il valore dell'intercetta al valore stimato si presenta come la seguente:

$$\begin{aligned}
 Vol_sales = & (seasonal_index_prohet^{c_stag}) \cdot (\log(Base_price)^{c_base_price}) \cdot \\
 & ((NEW_DATA_NMR^{0.5})^{c_ref}) \cdot (40690 + c_promo \cdot Promo_intensity) + c_target \cdot \\
 & GRP_target_trasformed + c_hc_1 \cdot GRP_hc_1_trasformed + c_hc_2 \cdot \\
 & GRP_hc_2_trasformed + c_display \cdot display_trasformed + c_meta_youtube \cdot \\
 & meta_youtube_trasformed + c_video_social \cdot video_social_trasformed + c_search \cdot \\
 & search_trasformed + c_competitors \cdot competitors_trasformed
 \end{aligned}$$

che risulta implementata in R con la seguente sintassi:

```

modello_nlsLM_complete2 <- nlsLM(
  formula = df$Vol_Sales ~
    (seasonal_index_prophet ^ c_Stag) * (log(df$Base_price) ^ c_base_price) *
    (I(NEW_DATA_NMR^0.5) ^ c_ref) * (40690 + c_promo * df$Promo_Intensity) +
    c_target * df$GRP_target_transformed + c_hc_1 * df$GRP_hc_1_transformed +
    c_hc_2 * GRP_hc_2_transformed + c_display * df$display_trasformed +
    c_meta_youtube * df$meta_youtube_transformed + c_video_social * df$video_social_transformed +
    c_search * search_transformed + c_competitors * competitors_transformed

  data = df,
  start = start_values,
  lower = lower_bounds,
  upper = upper_bounds,
  control = nls.lm.control(maxiter = 1000, ftol = 1e-8)
)

```

Seguono i risultati del modello precedente dopo aver fissato il valore dell'intercetta al valore stimato.

```
> summary(modello_nlsLM_complete2)
```

```

Formula: df$Vol_Sales ~ ((seasonal_index_prophet^c_Stag) * (log(df$Base_price)^c_base_price) *
  (I(NEW_DATA_NMR^0.5)^c_ref)) * (40690 + c_promo * df$Promo_Intensity) +
  c_target * df$GRP_target_transformed + c_hc_1 * df$GRP_hc_1_transformed +
  c_hc_2 * df$GRP_hc_2_transformed + c_display * df$display_trasformed +
  c_meta_youtube * df$meta_youtube_transformed + c_video_social *
  df$video_social_transformed + c_search * search_transformed +
  c_competitors * competitors_transformed

```

Parameters:

	Estimate	Std. Error	t value	Pr(> t)	
c_Stag	6.280e-01	6.948e-02	9.039	3.97e-16	***
c_base_price	-3.305e+00	3.116e-01	-10.606	< 2e-16	***
c_ref	1.739e+00	2.235e-01	7.783	7.19e-13	***
c_promo	3.968e+04	8.089e+03	4.905	2.21e-06	***
c_target	2.477e+00	1.623e+00	1.526	0.12884	
c_hc_1	1.211e+00	1.618e+00	0.748	0.45524	
c_hc_2	-1.987e+00	1.854e+00	-1.072	0.28530	
c_display	7.470e-01	5.656e-01	1.321	0.18837	
c_meta_youtube	1.306e+00	4.749e-01	2.750	0.00662	**
c_video_social	1.782e-01	6.472e-01	0.275	0.78338	
c_search	8.494e-01	4.475e-01	1.898	0.05940	.
c_competitors	-2.039e+01	4.473e+00	-4.559	9.93e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2335 on 166 degrees of freedom

Number of iterations to convergence: 6

Achieved convergence tolerance: 1.49e-08

Come si può notare dai risultati ottenuti, si conferma la significatività dei coefficienti delle variabili inserite nella parte moltiplicativa, in particolare del coefficiente associato alle promozioni. Questa parte del modello è particolarmente importante poiché permette di spiegare una parte rilevante della variabilità delle vendite totali del prodotto. Inoltre, questi risultati sono

plausibili e attesi; difatti, stagionalità, prezzo, gamma di offerte del prodotto e le promozioni sono elementi fondamentali per garantire attrattività verso i consumatori. Per quanto riguarda invece le variabili legate al marketing pubblicitario, risulta di particolare rilevanza l'impatto sulle vendite della strategia attuata su Meta e YouTube, essendo il coefficiente associato a questa variabile significativo e stimato in misura superiore a uno. Risulta, invece, non significativo (sebbene il p -value sia di poco superiore a 0,05) il coefficiente di Search Marketing, stimato in 0,84, valore di poco sotto all'uno. Così come, a parità delle altre condizioni inserite nel modello, non risultano significativi gli impatti sulle vendite derivati dalle altre strategie di marketing, ossia la comunicazione televisiva, il display marketing e i video-social. Infine, un risultato che era atteso è la significatività del coefficiente dei competitors, che va a confermare l'effetto erosivo delle strategie di marketing dei competitors del settore.

Il modello appena mostrato presenta un valore dell' R^2 pari a 0,79, che rappresenta un buon risultato, a significare che il modello spiega circa l'80% della variabilità delle vendite.




Figura 23- grafico residui vs. valori previsti

La Figura 23 dei residui vs. valori previsti mostra i residui distribuiti intorno allo zero, senza apparenti pattern. Il test di Breusch-Pagan porta all'accettazione dell'ipotesi nulla di

omoschedasticità degli errori del modello (sebbene il p -value sia di poco superiore al livello di 0,05).

```
> bptest(residuals(modello_nlsLM_completo2) ~ fitted(modello_nlsLM_completo2))  
  
studentized Breusch-Pagan test  
  
data: residuals(modello_nlsLM_completo2) ~ fitted(modello_nlsLM_completo2)  
BP = 3.5894, df = 1, p-value = 0.05815
```

La Figura 24, che riporta l'analisi grafica di diagnostica della normalità dei residui, mostra una deviazione dalla distribuzione normale, in particolare nelle code.




Figura 24- QQ Plot

A seguito dei primi risultati del modello finale, un'ulteriore analisi delle variabili media trasformate con l'Adstock i cui coefficienti non sono risultati significativi, come i GRP_target e GRP_h/c_2, ha evidenziato un'asimmetria nelle distribuzioni di queste variabili. Questa asimmetria positiva è dovuta ad un'elevata presenza di valori pari a 0, che rappresentano l'inattività delle campagne marketing. Quanto descritto è rappresentato dai grafici riportati nella Figura 25.




Figura 25- istogrammi dei GRP del prodotto target e di un prodotto correlato

Per ovviare all'asimmetria, stabilizzare la varianza e migliorare le performance del modello, è stata valutata una trasformazione logaritmica alle variabili “GRP_target_trasformed” e “GRP_h/c_2”. L'equazione del modello è la seguente:

$$\begin{aligned}
 Vol_sales = & (seasonal_index_prohet^{c_{stag}}) \cdot (\log(Base_price)^{c_{base_price}}) \cdot \\
 & ((NEW_DATA_NMR^{0.5})^{c_{ref}}) \cdot (40690 + c_{promo} \cdot Promo_intensity) + c_{target} \cdot \\
 & \log(GRP_target_trasformed) + c_{hc_1} \cdot GRP_hc_1_trasformed + c_{hc_2} \cdot \\
 & \log(GRP_hc_2_trasformed) + c_{display} \cdot display_trasformed + c_{meta_youtube} \cdot \\
 & meta_youtube_trasformed + c_{video_social} \cdot video_social_trasformed + c_{search} \cdot \\
 & search_trasformed + c_{competitors} \cdot competitors_trasformed
 \end{aligned}$$

che risulta implementata in R con la seguente sintassi:

```

modello_nlsLM_complete3 <- nlsLM(
  formula = df$Vol_Sales ~
    (seasonal_index_prophet ^ c_stag) * (log(df$Base_price) ^ c_base_price) *
    (I(NEW_DATA_NMR^0.5) ^ c_ref) * (40690 + c_promo * df$Promo_Intensity) +
    c_target * log(df$GRP_target_transformed+1) + c_hc_1 * df$GRP_hc_1_transformed +
    c_hc_2 * log(GRP_hc_2_transformed) + c_display * df$display_transformed +
    c_meta_youtube * df$meta_youtube_transformed + c_video_social * df$video_social_transformed +
    c_search * search_transformed + c_competitors * competitors_transformed

  data = df,
  start = start_values,
  lower = lower_bounds,
  upper = upper_bounds,
  control = nls.lm.control(maxiter = 1000, ftol = 1e-8)
)

```

I risultati del modello con questa trasformazione sono riportati di seguito:

```
> summary(modello_nlsLM_complete3)

Formula: df$Vol_Sales ~ ((seasonal_index_prophet^c_Stag) * (log(df$Base_price)^c_base_price) *
(I(NEW_DATA_NMR^0.5)^c_ref)) * (40690 + c_promo * df$Promo_Intensity) +
c_target * log(df$GRP_target_transformed + 1) + c_hc_1 *
df$GRP_hc_1_transformed + c_hc_2 * log(df$GRP_hc_2_transformed +
1) + c_display * df$display_trasformed + c_meta_youtube *
df$meta_youtube_transformed + c_video_social * df$video_social_transformed +
c_search * search_transformed + c_competitors * competitors_transformed

Parameters:
      Estimate Std. Error t value Pr(>|t|)
c_Stag      6.357e-01  6.822e-02   9.319  < 2e-16 ***
c_base_price -3.210e+00  2.979e-01 -10.773  < 2e-16 ***
c_ref        1.678e+00  2.139e-01   7.847  4.97e-13 ***
c_promo      3.839e+04  7.800e+03   4.921  2.06e-06 ***
c_target     1.399e+02  7.853e+01   1.781  0.07676 .
c_hc_1       8.119e-01  1.564e+00   0.519  0.60443
c_hc_2      -1.409e+02  1.069e+02  -1.318  0.18935
c_display    7.590e-01  5.465e-01   1.389  0.16680
c_meta_youtube 1.181e+00  4.348e-01   2.715  0.00732 **
c_video_social 3.291e-01  6.514e-01   0.505  0.61407
c_search     8.770e-01  4.481e-01   1.957  0.05204 .
c_competitors -2.012e+01  4.474e+00  -4.497  1.29e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2329 on 166 degrees of freedom

Number of iterations to convergence: 6
Achieved convergence tolerance: 1.49e-08
```

Il modello presenta un R^2 pari a 0,79, il che indica che non vi è alcun miglioramento in termini di bontà di adattamento ai dati rispetto al modello precedente, e un MAPE (*Mean Absolute Percentage Error*) dell'8%. Tutto ciò indica un buon adattamento complessivo del modello.

A differenza del modello precedente si nota una diminuzione generale degli standard error, come si osserva ad esempio per il coefficiente di “c_target”, che tuttavia anche in questo caso risulta non significativo (con un p -value pari a 0,077). Ad ogni modo, come è noto, la comunicazione televisiva del prodotto target è una strategia di marketing fondamentale nel contesto di business del prodotto trattato, così come il Search Marketing, anch'esso risultato ad impatto non significativo (sebbene con un p -value uguale a 0,052 e dunque di poco al di sopra del livello di significatività nominale). Una spiegazione plausibile per questi risultati riguarda il fatto che l'impatto di queste strategie di comunicazione è stato verificato al netto della presenza sui canali digitali Meta e YouTube di pubblicità del prodotto, che come già verificato in precedenza e confermato di nuovo, risulta essere una strategia particolarmente efficace.

Infine, poiché i coefficienti delle variabili che riguardano la comunicazione di altri prodotti dello stesso marchio e le vendite non sono risultati significativi, non si hanno particolari evidenze empiriche a supporto dell'esistenza di un effetto Halo o Cannibalization.

In definitiva, al fine di ottenere un modello più parsimonioso ma che comprendesse al contempo le strategie di marketing più importanti per il prodotto considerato, si è deciso di escludere dal modello precedente le variabili i cui coefficienti abbiano associato un livello di significatività empirico maggiore di 0,1. Sulla base di questo criterio, il modello finale (nel quale si è inclusa anche l'intercetta come parametro oggetto di stima) ha per equazione:

$$\begin{aligned}
 Vol_sales = & (seasonal_index_prophet^{c_{stag}}) \cdot (\log(Base_price)^{c_{base_price}}) \\
 & \cdot ((NEW_DATA_NMR^{0.5})^{c_{ref}}) \\
 & \cdot (intercetta + c_{promo} \cdot Promo_intensity) + c_{target} \\
 & \cdot \log(GRP_target_trasformed) + c_{meta_youtube} \\
 & \cdot meta_youtube_trasformed + c_{search} \cdot search_trasformed \\
 & + c_{competitors} \cdot competitors_trasformed
 \end{aligned}$$

che risulta implementata in R con la seguente sintassi:

```

modello_nlsLM_finale <- nlsLM(
  formula = df$Vol_Sales ~
    (seasonal_index_prophet ^ c_Stag) *
    (log(df$Base_price) ^ c_base_price) * (I(NEW_DATA_NMR^0.5) ^ c_ref) *
    (intercetta + c_promo * df$Promo_Intensity) + c_target * log(df$GRP_target_transformed + 1) +
    c_meta_youtube * df$meta_youtube_transformed + c_search * search_transformed +
    c_competitors * competitors_transformed,
  data = df,
  start = start_values,
  lower = lower_bounds,
  upper = upper_bounds,
  control = nls.lm.control(maxiter = 1000, fto1 = 1e-8)
)

```

i cui risultati sono presentati di seguito:

```

> summary(modello_nlsLM_finale)

Formula: df$Vol_Sales ~ (seasonal_index_prophet^c_Stag) * (log(df$Base_price)^c_base_price) *
  (I(NEW_DATA_NMR^0.5)^c_ref) * (intercetta + c_promo * df$Promo_Intensity) +
  c_target * log(df$GRP_target_transformed + 1) + c_meta_youtube *
  df$meta_youtube_transformed + c_search * search_transformed +
  c_competitors * competitors_transformed

Parameters:
      Estimate Std. Error t value Pr(>|t|)
c_Stag      6.307e-01  6.398e-02   9.858  < 2e-16 ***
c_base_price -3.190e+00  4.401e-01  -7.249 1.43e-11 ***
c_ref        1.692e+00  2.091e-01   8.094 1.08e-13 ***
intercetta   4.069e+04  1.926e+04   2.112  0.0362 *
c_promo      3.617e+04  1.835e+04   1.971  0.0503 .
c_target     1.500e+02  7.250e+01   2.070  0.0400 *
c_meta_youtube 1.255e+00  2.969e-01   4.227 3.88e-05 ***
c_search     8.917e-01  4.346e-01   2.052  0.0417 *
c_competitors -2.006e+01  4.416e+00  -4.543 1.05e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2334 on 169 degrees of freedom

Number of iterations to convergence: 18
Achieved convergence tolerance: 1.49e-08

```

Nel modello finale si conferma la significatività degli impatti, rispettivamente, della comunicazione televisiva del prodotto target, della comunicazione sui canali digitali Meta e YouTube e del Search marketing, così come la significatività dell'effetto erosivo dei competitors. Pertanto, è plausibile che queste siano le variabili che determinino la maggior parte delle vendite settimanali del prodotto in esame.

L' R^2 è pari a 0.79 mentre il MAPE è dell'8%, indicando come nei precedenti casi un buon adattamento del modello ai dati.




Figura 26. grafico residui vs. valori previsti

La Figura 26 non evidenzia pattern particolari nella distribuzione dei residui del modello rispetto ai valori previsti, come verificato anche dal test di Breusch-Pagan:

```
> bptest(residuals(modello_nlsLM_finale) ~ fitted(modello_nlsLM_finale))

studentized Breusch-Pagan test

data: residuals(modello_nlsLM_finale) ~ fitted(modello_nlsLM_finale)
BP = 2.2215, df = 1, p-value = 0.1361
```

Infine, per validare il modello e verificarne la stabilità e l'affidabilità delle stime è stato adottato il bootstrap, un metodo di ricampionamento preferibile in questo caso alla *cross-validation* poiché l'obiettivo principale di questo studio è la quantificazione dell'impatto delle variabili di marketing, e non la previsione delle vendite future. Sono stati utilizzati 1.000 campioni bootstrap, ognuno dei quali è stato ottenuto campionando con reinserimento dal dataset di origine. Sono state quindi costruite le distribuzioni bootstrap di R^2 , MAPE, MAE (*Mean Absolute Error*) e RMSE (*Root Mean Square Error*). I risultati di questa analisi sono riportati nella Figura 27 e nella Tabella 7.




Figura 27- istogrammi delle distribuzioni delle stime bootstrap

INDICI	MEDIA	DEV. STD	I.C (95%)
R²	0,7924	0,0307	0,7300 - 0,8485
MAPE	8,4129	0,6354	7,1408 - 9,6107
RMSE	2248,445	168,7276	1933,877 - 2569,232
MAE	1715,075	140,9503	1440,061 - 1983,954

Tabella 7- statistiche di sintesi delle stime bootstrap e intervalli di confidenza (I.C.) al 95%

La Figura 27 mostra le distribuzioni bootstrap di R^2 , MAPE, MAE e RMSE. Come si può osservare, le distribuzioni sono approssimativamente normali, ciò indica la stabilità delle stime dei parametri e l'affidabilità degli indici di performance del modello. Nel dettaglio, l' R^2 è pari a 0,7924, medesimo valore ottenuto per il modello finale, ed ha un intervallo di confidenza compreso tra 0,73 e 0,85. Il MAPE presenta un errore dell'8%, anche questo medesimo risultato ottenuto per il modello finale. Inoltre, gli intervalli di confidenza appaiono di ampiezza contenuta, a supporto di una valutazione di stabilità delle stime dei parametri ottenute nel modello finale.

I risultati del bootstrap permettono in definitiva di evidenziare l'accuratezza e l'affidabilità del modello finale, nel quale l'impatto significativo sulle vendite del prodotto è rappresentato dalle seguenti variabili: variabili di baseline, promozioni, comunicazione televisiva del prodotto in esame, strategia di marketing effettuata su YouTube e Meta, Search marketing e competitor. Si procede, nella sezione finale, alla decomposizione delle vendite e alla descrizione dei risultati ricavati dal modello e dell'analisi.

3.5 Risultati dell'analisi

Conclusa la fase di costruzione e validazione del modello finale, si procede con l'interpretazione e l'utilizzo dei risultati ottenuti al termine dell'analisi.

Le prime informazioni che si ricavano dal modello sono i contributi delle variabili. Viene effettuata una decomposizione delle vendite predette per determinare il numero di vendite derivate da ciascuna variabile. I contributi sono calcolati solo per le variabili con coefficienti significativi e che hanno dunque mostrato evidenze di relazione con la variabile target. Saranno quindi determinati per le variabili di baseline, le promozioni, la pressione pubblicitaria del prodotto analizzato, Impression di Meta e YouTube, Search marketing e attività dei competitor. Sulla base dell'equazione del modello finale le vendite totali generate da ogni variabile sono le seguenti:

Baseline	Promo	GRP TV	Meta_YouTube	Search	Competitors
2.424.437,08	880.919,47	88.459,08	218.992,43	154.592,36	-145.559,91

Tabella 8- decomposizione delle vendite

In termini percentuali le vendite si distribuiscono come segue:

Baseline	Promo	GRP TV	Meta_YouTube	Search	Competitors
66.939%	24.322%	2.442%	6.046%	4.268%	-4.018%

Tabella 9- decomposizione delle vendite in termini percentuali

Le Tabelle 8 e 9 e la Figura 28, che rappresenta graficamente la distribuzione delle vendite per ogni componente del modello, confermano quanto già era possibile cogliere dai risultati del modello. La baseline è un contributo unico calcolato per la stagionalità, il prezzo base e il numero di referenze medio e generano la maggior parte delle vendite, con un contributo pari circa al 67%. Si tratta di un valore atteso per un prodotto di un brand rilevante nella grande distribuzione, il cui acquisto è determinato per lo più dalla convenienza e dunque dal prezzo di

acquisto nei periodi dell'anno in cui la domanda è più elevata. A supporto di quanto affermato è possibile notare l'elevato contributo attribuito delle attività promozionali, con un valore pari al 24%.

Per quanto riguarda le attività mediatiche i contributi sono significativamente più bassi. Spiccano, tuttavia, le vendite attribuite alla strategia pubblicitaria effettuata su Meta e YouTube, pari a circa il 6% del totale, risultato di attività aggressive, come si nota dalla Figura 17 relativa alle distribuzioni grezze della pressione pubblicitaria. Un risultato importante è il contributo generato dalla strategia televisiva, che con un valore pari al 2%, determina un numero modesto di vendite. Una spiegazione di tale risultato potrebbe risiedere nella natura stessa del prodotto, più *digital-oriented* e ciò spiegherebbe anche l'elevato contributo generato da Meta e YouTube e dal Search marketing. Il basso contributo della televisione non implica necessariamente una strategia pubblicitaria inefficace, poiché agisce sulla parte alta del *funnel* di marketing (Figura 30), il modello che descrive il percorso del cliente dalla conoscenza del prodotto all'acquisto, incrementando in particolare la brand awareness e la considerazione del marchio sul mercato. Un ultimo risultato (atteso) è il contributo negativo generato dalle attività pubblicitarie dei maggiori competitor presenti sul mercato nel periodo analizzato, che erodono circa del 4% le vendite totali del prodotto.




Figura 28- decomposizione delle vendite

Ottenuto il contributo delle variabili incrementali si procede con il calcolo del ritorno sull'investimento (ROI). Anche in questo il caso il ROI viene analizzato per le variabili incrementali risultate significative. Il ROI “costituisce la misura della remunerazione del capitale investito”⁴⁴ ed è dato dal rapporto tra risultato operativo e capitale investito. I dati relativi agli investimenti totali di ciascuna strategia di marketing, necessari per il calcolo del ROI, sono la somma del capitale investito dal 2021 fino a giugno 2024 e sono rispettivamente:

GRP TV	Meta_YouTube	Search marketing
2.825.000	1.750.160	1.921.594

Tabella 10 - capitale investito

Dalla Tabella 10, che presenta l'ammontare del capitale investito nelle diverse strategie di marketing, è possibile notare un netto discostamento dell'investimento nei mezzi televisivi, con un investimento pari a 2.825.000 euro. Tale valore rende evidente il costo pubblicitario significativo della televisione, nettamente più elevato rispetto ai canali digitali ed altre tipologie di marketing, che unito ad un modesto contributo di vendite generate, produrrà un ritorno sull'investimento molto più basso rispetto alle altre strategie risultate significative. A conferma di quanto affermato la Figura 29 mostra il ROI ottenuto per ciascuna strategia analizzata.

⁴⁴ Borsa Italiana. *Glossario finanziario - Return on Investments*. URL <https://www.borsaitaliana.it/borsa/glossario/return-on-investments.html>




Figura 29- ROI strategie marketing

I risultati ottenuti evidenziano performance ben distinte tra i canali di marketing considerati. La strategia effettuata su Meta e YouTube si conferma la più performante, come si è osservato anche dalle Tabelle 8 e 9 e dalla Figura 28, con un ritorno sull'investimento del 57,40%, generando un profitto di 0,57 euro per ogni euro investito. Questo risultato sottolinea l'efficacia della strategia adottata su questa piattaforma, in grado di generare un ritorno significativo. Per quanto riguarda il Search marketing, pur mostrando un ROI positivo dell'1,20%, produce un rendimento inferiore rispetto a Meta_YouTube, con un profitto di 0,012 euro per ogni euro speso. Questo indica che il Search marketing, sebbene generi un ritorno positivo, contribuisce in misura minore alla redditività complessiva. Infine, GRP TV registra un ROI negativo del 60,61%, evidenziando una perdita di 0,60 euro per ogni euro investito, a dimostrazione dell'inefficacia di tale strategia nel generare conversioni. Un risultato simile è atteso dato il basso contributo osservato per tale mezzo e l'alto capitale investito. Tuttavia, come già avanzato in precedenza, il ROI negativo della televisione non ne implica necessariamente l'inefficacia, in quanto, come mostrato nella sezione relativa alla trasformazione delle variabili media e alla stima dei parametri di *alpha* e *decay*, per i mezzi televisivi questi parametri hanno valori elevati, ad indicare una saturazione del canale lenta e un ricordo del consumatore prolungato. La

televisione, consentendo di "toccare un vasto pubblico con facilità"⁴⁵, rimane un mezzo pubblicitario potente nonostante la crescita di Internet. Questo permette di influenzare la *brand awareness*, che gioca un ruolo cruciale nel processo decisionale d'acquisto, e può favorire il *brand recognition* grazie alla sua componente visiva. Questi elementi rappresentano le componenti della parte alta del funnel di marketing, illustrato nella Figura 30.




Figura 30 - funnel di marketing⁴⁶

Come discusso in precedenza, un ROI elevato, o negativo nel caso della TV, non implica necessariamente la massimizzazione dell'efficacia, né tantomeno che la strategia sia inefficace. Difatti ciò porterebbe ad investire solo nei canali con un ROI positivo ed elevato. Tuttavia, dalle ipotesi sollevate in seguito all'interpretazione del risultato negativo ottenuto dall'investimento pubblicitario televisivo, segue che spostare l'intero budget sui canali con ROI più alto è sbagliato poiché tale strategia ignora gli effetti dell'advertising sulla brand awareness, la necessità di un media mix diversificato e la legge dei rendimenti decrescenti. Le curve di saturazione offrono informazioni preziose in merito a tale tematica permettendo di identificare i canali in cui investire ulteriormente fornendo, dunque, indicazioni su come bilanciare gli investimenti tra i diversi canali.

Le Figure 31, 32 e 33 mostrano le curve di saturazione per le variabili media analizzate in questa fase finale, ottenute tramite la trasformazione descritta nella Sezione 3.3. Osservando la Figura

⁴⁵ Khuong M. N., Hoa N. V. A., & Nguyen T. D. (2016). *The Effect of Television Commercials on Customers' Loyalty--A Mediation Analysis of Brand Awareness*. International Journal of Trade, Economics and Finance, vol. 7(2).

⁴⁶ SproutSocial. *Marketing funnel*. URL <https://sproutsocial.com/it/glossary/marketing-funnel/>

31, la curva di saturazione di Meta_YouTube mostra una crescita iniziale rapida che tende poi a stabilizzarsi intorno ai 7-8 milioni di impression. Tale osservazione è supportata dai parametri *alpha* e *decay*, pari rispettivamente a 0,412 e 0,619. Considerando che la mediana delle impression, escludendo i periodi di inattività, è di circa 8,6 milioni, il punto di saturazione si colloca leggermente al di sotto della mediana, suggerendo che investimenti oltre tale soglia potrebbero essere soggetti a rendimenti decrescenti. La curva di saturazione della televisione (Figura 33), invece, evidenzia una crescita più lineare, con un punto di saturazione oltre i 250 GRP. Questo suggerisce che gli investimenti televisivi, nel periodo analizzato, si sono mantenuti al di sotto del punto di saturazione e che incrementi di spesa potrebbero generare ritorni maggiori; ciò è in linea con quanto affermato in precedenza su tale strategia pubblicitaria. Infine, la curva di saturazione del Search Marketing (Figura 32), mostra un andamento iniziale più ripido, per poi rallentare. I parametri *alpha* e *decay*, pari a 0,5990 e 0,5187, confermano una tendenza alla saturazione, anche se meno pronunciata rispetto a Meta_YouTube. Queste curve evidenziano l'importanza di bilanciare gli investimenti tra i diversi canali, considerando sia il ROI che il punto di saturazione di ciascuno, al fine di massimizzare l'efficacia complessiva del marketing mix.




Figura 31- curva di saturazione di Meta_YouTube




Figura 32 - curva di saturazione del Search Marketing




Figura 33- curva di saturazione di GRP TV

Conclusioni

Come affermato nell'introduzione, la presente tesi ha fornito una disamina del Marketing Mix Model, esplorandone i fondamenti teorici e verificandone l'utilità pratica attraverso un caso studio reale. L'obiettivo è stato quello di mostrare come questi modelli possano essere utilizzati per quantificare l'impatto delle diverse leve di marketing sulle vendite e per supportare le decisioni strategiche delle aziende.

Il secondo capitolo ha introdotto i concetti teorici fondamentali del MMM, come le trasformazioni Adstock e le curve di saturazione, poi applicati nel terzo capitolo, dedicato al caso studio su un prodotto appartenente alla linea skincare.

L'analisi condotta in tale capitolo ha permesso di mettere in pratica i concetti teorici di questi modelli confermandone l'utilità nel contesto reale del marketing.

In relazione al prodotto analizzato, i risultati del caso studio hanno evidenziato come prezzo, numero di referenze del prodotto, stagionalità, facenti parte delle variabili di base, e le promozioni siano i principali driver delle vendite, generando rispettivamente il 67% e il 24% delle vendite totali. Questo risultato conferma l'importanza di considerare i fattori di base del mercato e l'efficacia delle promozioni nell'influenzare le vendite del prodotto analizzato.

Per quanto riguarda le attività media, tra le variabili incluse nell'analisi hanno mostrato un impatto statisticamente significativo sulle vendite: i GRP del prodotto considerato, le impression di Meta e YouTube e il Search marketing. In particolare, la strategia più redditizia è quella effettuata su Meta e YouTube, che ha contribuito positivamente generando circa il 6% delle vendite, con un ritorno sull'investimento pari al 57%, dovuto anche al basso costo del mezzo. Contrariamente, la strategia di marketing televisiva risulta poco efficace con un contributo pari a circa il 2%. Le modeste vendite associate a questa variabile, unite al costo elevato del mezzo televisivo, ha prodotto un ROI negativo, evidenziando un mancato recupero dell'investimento. Infine, il Search Marketing risulta moderatamente efficace, con un contributo pari a circa il 4% delle vendite totali e un ROI pari all'1,2%, a conferma dell'impatto positivo di tale strategia seppur con un profitto piuttosto modesto, dettato dal fatto che non tutti i click monitorati generino una conversione. Inoltre, le curve di saturazione forniscono ulteriori informazioni e sono a supporto dei professionisti del marketing per un'allocazione del budget ottimale. Ad esempio, l'elevato ROI di Meta e YouTube non implica che incrementare ulteriormente gli investimenti su questo canale sia la strategia ottimale, in quanto la curva di saturazione relativa a Meta_Youtube suggerisce che il canale inizia a saturare intorno a 7-8 milioni di impression e investimenti oltre questa soglia potrebbero essere soggetti a rendimenti

decrementi. Pertanto, una strategia più efficace potrebbe essere quella di allocare parte del budget destinato a Meta e a YouTube, oltre il punto di saturazione, ad altri canali.

Il processo che ha condotto ai risultati presentati è stato ampiamente discusso nel terzo capitolo del caso studio. Le metodologie e gli strumenti impiegati si sono resi necessari per superare le limitazioni intrinseche dell'analisi. Ad esempio, come già evidenziato nel capitolo dedicato, la multicollinearità tra le variabili, in particolare nel modello non lineare utilizzato, ha rappresentato un aspetto di grande criticità che ha reso necessario stimare separatamente i parametri *alpha* e *decay*. Nello specifico, questi parametri, che definiscono la trasformazione delle variabili mediatriche, sono stati stimati per ogni singola variabile media in un modello preliminare. Successivamente, le variabili mediatriche trasformate sono state utilizzate in un modello finale per stimare il loro effettivo impatto sulle vendite. Per quanto riguarda la modellizzazione dell'effetto pubblicitario, inizialmente si è fatto ricorso a curve di saturazione sigmoidali. Tuttavia, a causa di problemi di instabilità, si è optato per curve a "C", più semplici, robuste e controllabili, a discapito della capacità interpretativa che fornivano le curve a "S". Un ulteriore ostacolo è stata la convergenza dell'algoritmo di ottimizzazione: per risolvere i vari problemi di convergenza occorsi nel processo di stima dei parametri del modello, si è utilizzato l'algoritmo *nlsLM* del pacchetto *minpack.lm* del software R al posto dell'algoritmo *nls*, anche perché *nlsLM* si è dimostrato meno sensibile all'inizializzazione dei suoi parametri.

In definitiva, la combinazione delle varie soluzioni adottate, ossia la mitigazione della multicollinearità attraverso la stima separata dei parametri di trasformazione, la selezione di parametri di trasformazione plausibili, la modellizzazione della stagionalità con Prophet e le trasformazioni introdotte per stabilizzare le stime dei coefficienti delle variabili indipendenti, ha consentito di sviluppare un modello finale affidabile con un buon adattamento ai dati, considerati l'indice R^2 pari a 0,79 e il MAPE pari all'8%, indici successivamente validati tramite bootstrap con 1.000 repliche.

Oltre alle limitazioni appena descritte, relative alla fase di costruzione del modello e a quelle intrinseche dei marketing mix model (come la difficoltà nel catturare gli effetti a lungo termine, discusse nella sezione 2.5) è importante segnalare l'assenza della *brand awareness* tra le variabili indipendenti. Questa esclusione è dovuta alla natura dei dati a disposizione: le rilevazioni sulla *brand awareness* iniziano solo dal 2022, un anno dopo l'inizio del periodo di analisi, hanno una frequenza bisettimanale anziché settimanale e, infine, presentano incertezze relative alla metodologia di calcolo e di raccolta dei dati.

Tali limitazioni potrebbero essere affrontate con approcci alternativi, utilizzando modelli più avanzati e robusti alla multicollinearità, tra cui i modelli Bayesiani, al fine di

consentire un'analisi più granulare e flessibile. Vi sono poi marketing mix model basati su IA e machine learning come Robyn, già citato nel capitolo relativo al caso studio, sviluppato da Meta e che è in grado di produrre output facilmente interpretabili. Tuttavia, tale strumento risulta ancora poco flessibile e personalizzabile e, inoltre, non lavora con i dati di pressione pubblicitaria, ma con gli investimenti, fornendo anche funzionalità di ottimizzazione del budget.

In conclusione, questo lavoro di tesi ha mostrato l'utilità e l'applicabilità dei Marketing Mix Model per l'analisi e l'ottimizzazione delle strategie di marketing. Il caso studio, condotto in applicazione dei concetti teorici presentati nel secondo capitolo, ha messo in evidenza sia l'importanza di un approccio quantitativo al marketing, sia la capacità dei MMM di fornire indicazioni preziose per lo sviluppo di strategie efficaci di business.

Bibliografia

Agarwal Y. (2023). *Non Linear Least Square*. Scaler Topics. URL <https://www.scaler.com/topics/non-linear-least-square-in-r/> .

Auditel. *Glossario*. URL <https://www.auditel.it/glossario/> .

Borsa Italiana. *Glossario finanziario - Return on Investments*. URL <https://www.borsaitaliana.it/borsa/glossario/return-on-investments.html>

Brue S. L. (1993). *Retrospectives: The law of diminishing returns*. Journal of Economic Perspectives, 7(3).

Cain P. M. (2008). *Limitations of conventional marketing mix modelling*. Admap Magazine, (493), 48-51.

Dr. R. Jarrar, Mass Analytics. *Your Comprehensive Marketing Mix Modeling Guide*.

Goi C. L. (2009). *A review of marketing mix: 4Ps or more*. International journal of marketing studies, 1(1).

Joseph J. V. (2006). *Understanding advertising Adstock transformations*.

Khuong M. N., Hoa N. V. A., & Nguyen T. D. (2016). *The Effect of Television Commercials on Customers' Loyalty--A Mediation Analysis of Brand Awareness*. International Journal of Trade, Economics and Finance, vol. 7(2).

Kisilevich S. (2022). *Modeling Marketing Mix using PyMC3*. Towards Data Science. URL <https://towardsdatascience.com/modeling-marketing-mix-using-pymc3-ba18dd9e6e68> .

Kisilevich S. (2023). *Exploring Different Approaches to Generate Response Curves in Marketing Mix Modeling*. Towards Data Science. URL <https://towardsdatascience.com/exploring-different-approaches-to-generate-response-curves-in-marketing-mix-modeling-ff6dcc7927f7> .

LatentView (2019). *A complete guide to Marketing Mix Modeling and use cases*. URL <https://www.latentview.com/wp-content/uploads/2019/08/Marketing-Mix-Model.pdf> .

McCool J. I. (2012). *Using the Weibull distribution: reliability, modeling, and inference* (Vol. 950). John Wiley & Sons.

Meta. *Robyn*. URL <https://facebookexperimental.github.io/Robyn/>.

Nielsen. *Da sapere: Qual è la differenza tra OTT, CTV e streaming?* URL <https://www.nielsen.com/it/insights/2024/whats-the-difference-ott-vs-ctv/> .

S. Pandey, S. Gupta, S. Chhajed. (2021). *Marketing Mix Modeling (MMM) – Concepts and Model Interpretation*. INTERNATIONAL JOURNAL OF ENGINEERING RESEARCH & TECHNOLOGY (IJERT) Volume 10, Issue 06.

SproutSocial. *Marketing funnel*. URL <https://sproutsocial.com/it/glossary/marketing-funnel/> .

T. V. Elzhov, K. M. Mullen, A.-N. Spiess, B. Bolker. (2023). *R Interface to the Levenberg-Marquardt Nonlinear Least-Squares Algorithm Found in MINPACK, Plus Support for Bounds*. URL <https://cran.r-project.org/web/packages/minpack.lm/minpack.lm.pdf>.

Y. Jin, Y. Wang, Y. Sun, D. Chan, J. Koehler. (2017). *Bayesian methods for media mix modeling with carryover and shape effects*. Google Inc.

Acceleration, WPP Company. Manuale aziendale.

Appendice

Descrizione sintetica delle variabili nel dataset di origine

Etichetta	Descrizione della variabile
Week_Ending	Variabile temporale, rappresenta l'ultimo giorno di ogni settimana.
Vol_Sales	Vendite settimanali del prodotto target a volume.
€_Sales	Vendite settimanali del prodotto target a valore.
Average_price	Prezzo medio di vendita, non depurato dalle promozioni.
NEW_DATA_NMR	Numero di referenze medio.
€_in_Promo	Vendite settimanali del prodotto target a valore effettuate sotto promozioni.
Volume_in_Promo	Vendite settimanali del prodotto target a volume effettuate sotto promozioni.
Base_€	Vendite a valore settimanali del prodotto target depurate dalle promozioni.
Base_Volume	Vendite a volume settimanali del prodotto target depurate dalle promozioni.
Base_price	Prezzo medio di vendita depurato dalle promozioni.
Promo_Intensity	Percentuale di vendite settimanali a volume effettuate in promozione.
SEASONALITY	Indice di stagionalità.
TRADE_VOLANTINI	Attività promozionale legata alla distribuzione di volantini nei punti vendita.
GRP_target	Distribuzione dei GRP della pubblicità televisiva del prodotto target.
GRP_h/c_1	Distribuzione dei GRP della pubblicità televisiva di un prodotto della stessa linea dell'azienda per valutare effetto halo/cannibalization.
GRP_h/c_2	Distribuzione dei GRP della pubblicità televisiva di un prodotto della stessa linea dell'azienda per valutare effetto halo/cannibalization.
Imp_ADDRES	Impression dell' <i>Addressable advertising</i> , ovvero di annunci personalizzati per il pubblico target sui canali digitali.
Imp_DISPLAY_AMAZON	Impression del Display Marketing monitorato su Amazon.
Imp_DISPLAY_GOOGLE	Impression del Display Marketing monitorato su Amazon.
Imp_VIDEO_AMAZON	Impression dei video monitorati su Amazon.
Imp_VIDEO_YT	Impression dei video monitorati su YouTube.
Imp_VIDEO_OTHER	Impression dei video monitorati su altre piattaforme.

Etichetta	Descrizione della variabile
Imp_META	Impression della pubblicità digitale monitorata su Meta.
Imp_TIK_TOK	Impression della pubblicità digitale monitorata su TikTok.
Imp_PINTEREST	Impression della pubblicità digitale monitorata su Pinterest.
CLICK_Search_Amazon	Click monitorati per il Search marketing effettuato su Amazon.
CLICK_Search_Google	Click monitorati per il Search marketing effettuato su Google.